



UMCS

UNIwersytet Marii Curie-Skłodowskiej
w Lublinie

Wydział Matematyki, Fizyki i Informatyki

Kierunek: **informatyka**

Oliwia Groszek

nr albumu: 307405

Badanie efektywności algorytmów sterowania w systemach zamkniętej pętli CGM–pompa insulinowa

Evaluation of the Effectiveness of Control Algorithms
in Closed-Loop CGM–Insulin Pump Systems

Praca magisterska

napisana w Katedrze Neuroinformatyki i Inżynierii Biomedycznej

pod kierunkiem **prof. dr hab. Grzegorza Wójcika**

Lublin 2026

Spis treści

1	Wstęp	7
1.1	Cukrzyca a technologia	7
1.2	Wyzwania w codziennym życiu	8
1.3	Systemy zamkniętej pętli	10
2	Wykorzystane narzędzia	13
2.1	Model fizjologiczny pacjenta (model Bergmana)	13
2.2	Model systemu CGM	15
2.3	Regulator PID	17
2.3.1	Działanie regulatora	17
2.3.2	Człon proporcjonalny	18
2.3.3	Człon całkujący	18
2.3.4	Człon różniczkujący	19
2.3.5	Zastowosanie PID	19
2.4	Regulator MPC	20
2.4.1	Model predykcyjny	20
2.4.2	Funkcja kosztu	21
2.4.3	Horyzont predykcji i horyzont sterowania	21
2.4.4	Zalety MPC	21
2.4.5	Ograniczenia MPC	22
2.5	Regulator oparty na uczeniu ze wzmocnieniem	22
2.5.1	Podstawowe elementy uczenia ze wzmocnieniem	23
2.5.2	Zastosowanie RL w sterowaniu glikemią	23
2.5.3	Wybór metody uczenia	24
2.5.4	Zasada działania regulatora RL	24
2.5.5	Zalety regulatorów RL	25
2.5.6	Ograniczenia i ryzyka	26
3	Przebieg badania	27
3.1	Środowisko badawcze i narzędzia	27

3.1.1	Parametry symulacji	27
3.1.2	Implementacja modelu Bergmana	29
3.1.3	Model pojawiania się glukozy po posiłku	31
3.1.4	Model systemu CGM	31
3.1.5	Symulacja modelu bez udziału regulatora	33
3.2	Scenariusze badawcze	33
3.3	Scenariusz A i implementacja regulatorów	34
3.3.1	Regulator PID	34
3.3.2	Regulator MPC	38
3.3.3	Regulator RL	42
3.4	Scenariusz B	49
3.4.1	Regulator PID	49
3.4.2	Regulator MPC	51
3.4.3	Regulator RL	52
3.5	Scenariusz C	53
3.5.1	Regulator PID	54
3.5.2	Regulator MPC	55
3.5.3	Regulator RL	56
3.6	Scenariusz D	57
3.6.1	Regulator PID	57
3.6.2	Regulator MPC	59
3.6.3	Regulator RL	60
4	Wyniki i wnioski	63
4.1	Kryteria oceny	63
4.1.1	Czas w zakresie	63
4.1.2	Średni poziom glukozy	64
4.1.3	Epizody hipoglikemii i hiperglikemii	65
4.1.4	Zużycie insuliny	65
4.1.5	Stabilność i oscylacje glikemii	66
4.2	Wyniki	66
4.3	Wnioski	68
	Spis listingów	71
	Spis tabel	73
	Spis rysunków	75

Rozdział 1

Wstęp

Cukrzyca typu 1 jest przewlekłą chorobą autoimmunologiczną, w której dochodzi do stopniowego niszczenia komórek beta wysp trzustkowych odpowiedzialnych za produkcję insuliny [26]. Skutkiem tego procesu jest bezwzględny niedobór insuliny, czyli hormonu niezbędnego do prawidłowego wykorzystania glukozy przez komórki organizmu. Brak odpowiedniego leczenia prowadzi do utrzymującej się hiperglikemii oraz poważnych zaburzeń metabolicznych, które mogą stanowić bezpośrednie zagrożenie dla życia pacjenta.

Podstawą terapii cukrzycy typu 1 jest dostarczanie insuliny z zewnątrz oraz utrzymywanie poziomu glukozy we krwi w możliwie bezpiecznym zakresie. Leczenie wymaga regularnego monitorowania glikemii i dostosowywania dawki insuliny do aktualnego stanu pacjenta, spożywanych posiłków, aktywności fizycznej oraz wielu innych czynników wpływających na metabolizm glukozy.

Niewystarczająca kontrola glikemii może prowadzić zarówno do powikłań ostrych, takich jak hipoglikemia, hiperglikemia czy cukrzycowa kwasica ketonowa, jak i do powikłań przewlekłych, obejmujących między innymi uszkodzenie naczyń krwionośnych, nerek, nerwów oraz siatkówki oka [16]. Z tego względu precyzyjne monitorowanie poziomu glukozy oraz właściwe dawkowanie insuliny mają kluczowe znaczenie w leczeniu cukrzycy typu 1.

1.1 Cukrzyca a technologia

Współczesna diabetologia w coraz większym stopniu wykorzystuje rozwiązania technologiczne, które wspomagają pacjentów w codziennym zarządzaniu chorobą. Zanim możliwe stało się samodzielne oznaczanie poziomu glukozy za pomocą glukometrów, kontrola cukrzycy opierała się głównie na badaniach laboratoryjnych oraz pośrednich metodach oceny, takich jak oznaczanie obecności glukozy w moczu. Metody

te dostarczały jedynie ograniczonych informacji o aktualnym stanie metabolicznym pacjenta i nie pozwalały na bieżącą ocenę zmian glikemii w ciągu dnia.

Kolejnym etapem rozwoju były glukometry, umożliwiające pomiar poziomu glukozy z próbki krwi kapilarnej. Początkowo urządzenia te były wykorzystywane przede wszystkim w placówkach medycznych, a ich zastosowanie w warunkach domowych było ograniczone. Dopiero dalszy rozwój technologii, miniaturyzacja urządzeń oraz uproszczenie procedury pomiarowej sprawiły, że glukometry stały się powszechnym narzędziem samokontroli pacjentów z cukrzycą. Choć cechowały się dużą przydatnością kliniczną, wymagały częstego wykonywania pomiarów manualnych oraz prowadzenia dziennika wyników, co bywało dla pacjentów uciążliwe i wpływało na regularność kontroli.

Kolejnym krokiem w rozwoju technologii diabetologicznych były systemy ciągłego monitorowania glukozy, określane jako CGM (ang. *Continuous Glucose Monitoring*). Umożliwiają one automatyczny pomiar stężenia glukozy bez konieczności każdorazowego nakłuwania palca. Czujnik CGM umieszczany jest podskórnie i dokonuje pomiarów co kilka minut, a dane przesyłane są bezprzewodowo do odbiornika lub aplikacji mobilnej. Systemy te dostarczają użytkownikowi informacji o bieżącym poziomie glukozy, trendzie zmian oraz umożliwiają ustawienie progów alarmowych. Dzięki temu pacjent może szybciej reagować na sytuacje potencjalnie niebezpieczne, takie jak hipoglikemia lub hiperglikemia.

W ostatnich latach coraz większe znaczenie zyskują również pompy insulinowe, które automatyzują proces podawania insuliny i zastępują samodzielne wykonywanie części iniekcji przez pacjenta. Pompa dostarcza hormon w sposób ciągły, w postaci tzw. dawki bazalnej, oraz umożliwia podanie dodatkowych dawek, czyli bolusów, na przykład w czasie posiłków. Połączenie pompy insulinowej z systemem CGM otworzyło drogę do tworzenia systemów zamkniętej pętli, które mogą samodzielnie regulować ilość podawanej insuliny na podstawie aktualnych danych pomiarowych [20].

Rozwój technologii czujników, łączności bezprzewodowej oraz algorytmów analitycznych przyczynił się do zwiększenia bezpieczeństwa terapii i komfortu życia osób z cukrzycą. Obecnie wiele urządzeń CGM, takich jak Dexcom, FreeStyle Libre czy Medtronic Guardian, może integrować się z platformami mobilnymi i aplikacjami zdrowotnymi, co umożliwia gromadzenie oraz analizę danych z różnych źródeł w jednym ekosystemie.

1.2 Wyzwania w codziennym życiu

Pomimo znaczącego rozwoju technologii diabetologicznych osoby chorujące na cukrzycę typu 1 nadal napotykały liczne trudności w codziennym funkcjonowaniu. Utrzy-

manie glikemii w bezpiecznym zakresie wymaga nieustannego podejmowania decyzji związanych z dawkowaniem insuliny, sposobem odżywiania, aktywnością fizyczną oraz interpretacją aktualnych i przewidywanych zmian poziomu glukozy. Szacuje się, że osoba z cukrzycą typu 1 może podejmować nawet około 180 decyzji zdrowotnych dziennie, co pokazuje skalę obciążenia poznawczego związanego z samokontrolą choroby [11]. Na poziom glukozy wpływa wiele czynników, których działanie może różnić się między pacjentami oraz zmieniać się w czasie. Do najważniejszych z nich należą:

- skład posiłku, w szczególności ilość i rodzaj węglowodanów, białek oraz tłuszczów,
- czas spożycia posiłku oraz odstęp między posiłkiem a podaniem insuliny,
- kolejność spożywania poszczególnych składników odżywczych,
- aktywność fizyczna, jej intensywność oraz czas trwania,
- stres, jakość snu oraz zmęczenie,
- alkohol, kofeina oraz inne używki,
- choroby towarzyszące, infekcje i stany zapalne,
- faza cyklu menstruacyjnego,
- przyjmowane leki,
- czynniki środowiskowe, takie jak wysoka lub niska temperatura otoczenia.

Złożoność codziennego zarządzania cukrzycą wynika z tego, że wymienione czynniki mogą oddziaływać jednocześnie i wzajemnie się wzmacniać. Przykładowo aktywność fizyczna może zwiększać wrażliwość tkanek na insulinę, stres może prowadzić do wzrostu glikemii, a infekcja może czasowo zwiększać zapotrzebowanie organizmu na insulinę. W praktyce oznacza to, że ta sama dawka insuliny lub ten sam posiłek nie zawsze wywołują identyczną odpowiedź metaboliczną. Z tego powodu pacjent musi nie tylko reagować na aktualny poziom glukozy, ale również przewidywać jego dalsze zmiany.

Dodatkowym utrudnieniem są ograniczenia systemów ciągłego monitorowania glukozy. Czujniki CGM nie mierzą bezpośrednio stężenia glukozy we krwi, lecz stężenie glukozy w płynie śródtkankowym. Powoduje to opóźnienie odczytu względem rzeczywistego poziomu glukozy we krwi, szczególnie w sytuacjach gwałtownych zmian, na przykład po posiłku, po podaniu insuliny lub w trakcie aktywności fizycznej. W literaturze wskazuje się, że opóźnienie to może wynosić około kilkunastu minut [8, 18]. W

praktyce oznacza to, że wskazanie sensora może nie odzwierciedlać natychmiastowego stanu pacjenta.

Odczyty CGM mogą być również obarczone szumem pomiarowym, błędami kalibracji, chwilowymi zakłóceniami transmisji lub pojedynczymi wartościami odstającymi. Ma to istotne znaczenie w dawkowaniu insuliny, ponieważ decyzje podejmowane są na podstawie danych pomiarowych, które mogą być opóźnione lub zaburzone. Zbyt gwałtowna reakcja na błędny odczyt mogłaby prowadzić do nieprawidłowego dawkowania insuliny, a w konsekwencji zwiększać ryzyko hipoglikemii lub hiperglikemii.

W rezultacie, pomimo dostępności zaawansowanych technologii, pacjenci nadal muszą podejmować wiele decyzji samodzielnie, co wymaga wiedzy, doświadczenia i systematyczności.

1.3 Systemy zamkniętej pętli

Systemy zamkniętej pętli (ang. *Closed Loop Systems*), nazywany także “sztuczną trzustką” [9], stanowią jedno z najważniejszych osiągnięć współczesnej diabetologii. Ich głównym celem jest automatyczne utrzymywanie poziomu glukozy możliwie blisko wartości docelowych bez ingerencji użytkownika poprzez ciągłą współpracę trzech elementów:

- systemu CGM,
- pompy insulinowej,
- algorytmu sterowania odpowiedzialnego za wyznaczenie dawki insuliny.

W klasycznym systemie zamkniętej pętli dane z sensora CGM są analizowane przez algorytm sterujący, który na bieżąco oblicza ilość insuliny potrzebnej do utrzymania prawidłowej glikemii. Wyznaczona dawka przekazywana jest do pompy, która ostatecznie podaje ją użytkownikowi. Proces ten odbywa się cyklicznie co kilka minut i tworzy automatyczne sprzężenie zwrotne pomiędzy pomiarem glukozy a podażą insuliny. W praktyce pełna automatyzacja jest jednak niezwykle trudna do osiągnięcia. Organizm człowieka stanowi bowiem układ nieliniowy, którego zachowanie zależy od wielu zmiennych trudnych do przewidzenia. Dodatkowym problemem są ograniczenia technologiczne sensorów CGM, takie jak opóźnienia pomiarowe, szумы oraz błędy odczytu. Równie istotne jest opóźnienie działania insuliny podawanej podskórnie - nawet szybko działające analogi insuliny ludzkiej zaczynają wpływać na glikemię dopiero po kilkunastu minutach, a pełny efekt ich działania może nastąpić po godzinie. Powoduje to, że regulator sterujący musi podejmować decyzje na podstawie niepełnych i

opóźnionych danych. Z tego względu obecnie systemy zamkniętej pętli są rzadkością, a najczęściej stosowane są tzw. hybrydowe systemy zamkniętej pętli (ang. *Hybrid Closed Loop*)[17]. W tych rozwiązaniach algorytm automatycznie reguluje dawkę bazalną oraz wykonuje korekty, jednak użytkownik nadal musi samodzielnie podawać informacje o spożywanych posiłkach oraz wprowadzać bolusy doposiłkowe. Oznacza to częściową automatyzację terapii przy jednoczesnym zachowaniu kontroli użytkownika nad najbardziej dynamicznymi zmianami glikemii. Hybrydowe systemy zamkniętej pętli znacząco poprawiły bezpieczeństwo i komfort życia osób chorych na cukrzycę typu 1. Badania kliniczne wskazują na zwiększenie parametru TIR (ang. *Time In Range*), zmniejszenie liczby epizodów hipoglikemii oraz ograniczenie obciążenia psychicznego związanego z ciągłym podejmowaniem decyzji terapeutycznych. Do najbardziej rozpoznanych komercyjnych systemów hybrydowych należą między innymi:

- system SmartGuard firmy Medtronic,
- system Control-IQ firmy Tandem Diabetes Care,
- system CamAPS FX opracowany przez CamDiab.

W ostatnich latach obserwowany jest dalszy rozwój technologii automatycznego sterowania insuliną. Jednym z zapowiadanych rozwiązań jest system CamAPS Liberty, rozwijany przez CamDiab we współpracy z sensorami nowej generacji firmy Abbott. System ten ma integrować algorytm sterowania bezpośrednio z urządzeniami CGM i pompą insulinową, zwiększając stopień automatyzacji terapii oraz zmniejszając liczbę interakcji wymaganych od użytkownika. Kolejnym rozwijanym rozwiązaniem jest system MiniMed Vivera firmy Medtronic, będący następcą obecnych systemów serii MiniMed. Zapowiadane funkcje obejmują bardziej zaawansowane algorytmy predykcyjne, lepsze dostosowanie terapii do stylu życia użytkownika oraz większą automatyzację procesu dawkowania insuliny. Rozwój takich systemów wskazuje, że przyszłość diabetologii będzie coraz silniej oparta na algorytmach sterowania, analizie danych oraz metodach sztucznej inteligencji.

Rozdział 2

Wykorzystane narzędzia

2.1 Model fizjologiczny pacjenta (model Bergmana)

W celu przeprowadzenia badań symulacyjnych konieczne było przyjęcie modelu matematycznego opisującego zależność pomiędzy poziomem glukozy oraz zewnętrzną podażą insuliny. W pracy wykorzystano uproszczony model oparty na tzw. minimalnym modelu Bergmana[1, 2]. Model ten został opracowany jako możliwie prosty opis dynamiki glukozy i insuliny, pozwalający analizować między innymi wrażliwość organizmu na insulinę oraz skuteczność usuwania glukozy z krwi[23]. Jest on często stosowany jako punkt wyjścia w badaniach nad algorytmami sterowania glikemią i systemami sztucznej trzustki[25].

Model Bergmana opisuje układ za pomocą trzech podstawowych zmiennych stanu:

$G(t)$ – stężenie glukozy we krwi,

$X(t)$ – zmienna opisująca opóźnione działanie insuliny w tkankach, określana w literaturze jako *remote insulin action*,

$I(t)$ – stężenie insuliny w osoczu [2].

W pracy model został zaadaptowany do symulacji osoby chorej na cukrzycę typu 1. Oznacza to, że przyjęto brak endogennej produkcji insuliny, a więc poziom insuliny zależy wyłącznie od sygnału sterującego odpowiadającego podaży insuliny przez pompę[25]. Takie uproszczenie pozwala analizować działanie regulatorów w warunkach, w których organizm pacjenta nie jest w stanie samodzielnie obniżyć poziomu glukozy poprzez wydzielanie insuliny. Zastosowany model opisano następującym ukła-

dem równań:

$$\begin{aligned}\frac{dG}{dt} &= -p_1(G - G_b) - XG + \frac{1}{V_g}R_a(t), \\ \frac{dX}{dt} &= -p_2X + p_3(I - I_b), \\ \frac{dI}{dt} &= -nI + \frac{1}{V_i}U(t).\end{aligned}\tag{2.1}$$

gdzie:

$G(t)$ - stężenie glukozy we krwi,

$X(t)$ - zmienna opisująca opóźnione działanie insuliny w tkankach,

$I(t)$ - stężenie insuliny w osoczu,

$R_a(t)$ - szybkość pojawiania się glukozy po posiłku,

$U(t)$ - insulina podawana zewnętrznym,

G_b - bazowy poziom glukozy we krwi,

I_b - bazowy poziom insuliny endogennej,

p_1 - tempo dążenia glukozy do poziomu równowagi,

p_2 - tempo zaniku insuliny w tkankach,

p_3 - wrażliwość organizmu na insulinę,

n - tempo usuwania insuliny z krwi,

V_g - współczynnik skalujący wpływ glukozy z posiłku,

V_i - współczynnik skalujący wpływ podanej insuliny.

W klasycznym modelu Bergmana parametr G_b oznacza wartość bazową glukozy w stanie równowagi. W pracy przyjęto jednak zmodyfikowaną interpretację, dostosowaną do cukrzycy typu 1. Parametr G_b został ustawiony na podwyższonym poziomie, reprezentującym stan przewlekłej hiperglikemii, do którego układ dąży w przypadku braku podaży insuliny. Takie założenie pozwala zasymulować sytuację, w której organizm osoby chorej na cukrzycę typu 1 nie produkuje własnej insuliny, a poziom glukozy wzrasta wskutek ciągłego uwalniania glukozy przez wątrobę.

Szczególnie istotny jest parametr p_3 , ponieważ odpowiada za siłę wpływu insuliny na zmienną $X(t)$, a więc pośrednio na tempo obniżania glukozy. Zbyt mała wartość

tego parametru powoduje, że insulina praktycznie nie wpływa na glikemię, natomiast zbyt duża może prowadzić do gwałtownych spadków poziomu glukozy. Z tego względu parametr ten ma kluczowe znaczenie podczas strojenia badanych regulatorów.

Model został zdyskretyzowany metodą Eulera, co oznacza, że kolejne wartości zmiennych stanu wyznaczone są w równych odstępach czasu. W symulacjach przyjęto krok czasowy odpowiadający typowej częstotliwości pracy systemów CGM i algorytmów sterowania. Dzięki temu możliwe było analizowanie działania regulatorów w warunkach zbliżonych do pracy rzeczywistego systemu zamkniętej pętli.

Zaletą modelu Bergmana jest jego prostota oraz niewielka liczba parametrów, co ułatwia analizę działania algorytmów sterowania. Jednocześnie model ten zachowuje podstawowe zależności fizjologiczne: wzrost glukozy po posiłku, opóźnione działanie insuliny oraz stopniowe usuwanie glukozy z organizmu. Minimalny model glukoza - insulina jest często stosowany właśnie dlatego, że stanowi kompromis pomiędzy interpretowalnością a zdolnością odwzorowania podstawowej dynamiki metabolicznej.

Należy jednak podkreślić, że model Bergmana jest modelem uproszczonym. Nie uwzględnia on w pełni takich zjawisk jak zmienność wrażliwości insulinowej w ciągu dnia, wpływ hormonów stresu, różnice między pacjentami, złożona kinetyka wchłaniania insuliny podskórnej czy szczegółowy wpływ aktywności fizycznej. Z tego względu w pracy model ten nie jest traktowany jako pełne odwzorowanie organizmu człowieka, lecz jako środowisko symulacyjne umożliwiające porównanie algorytmów sterowania w powtarzalnych warunkach.

Tak zdefiniowany model fizjologiczny pacjenta stanowi podstawę do dalszej analizy algorytmów sterowania. W kolejnych podrozdziałach przedstawiono trzy podejścia do automatycznego dawkowania insuliny: regulator PID, regulator predykcyjny MPC oraz regulator oparty na uczeniu ze wzmocnieniem.

2.2 Model systemu CGM

Systemy ciągłego monitorowania glukozy (CGM, ang. *Continuous Glucose Monitoring*) stanowią podstawowe źródło informacji zwrotnej w systemach zamkniętej pętli. W odróżnieniu od klasycznych pomiarów glukometrem, CGM nie mierzy bezpośrednio stężenia glukozy we krwi, lecz poziom glukozy w płynie śródtkankowym, co wprowadza istotne ograniczenia pomiarowe[5, 13].

Sygnał CGM składa się z następujących elementów:

- rzeczywistej glikemii krwi
- opóźnienia dyfuzyjnego pomiędzy krwią a płynem śródtkankowym

- szumu pomiarowego
- dryftu sensora
- sporadycznych błędów odczytu

Opóźnienie wynosi zazwyczaj od 5 do 15 minut i powoduje, że zmiany glikemii są obserwowane z opóźnieniem, co stanowi istotne wyzwanie dla algorytmów sterowania[6, 13].

Typowa częstotliwość próbkowania CGM wynosi 5 minut[22], co determinuje naturalny krok czasowy regulatorów w systemach zamkniętej pętli. Taka częstotliwość pomiaru ogranicza możliwości szybkiej reakcji na dynamiczne zmiany glukozy.

W kontekście systemów zamkniętej pętli niedoskonałość pomiaru CGM ma istotne znaczenie. Algorytm sterujący nie dysponuje bowiem idealną informacją o aktualnym stanie organizmu pacjenta. Podejmuje decyzje na podstawie sygnału opóźnionego, zaszumionego i potencjalnie obciążonego dryftem sensora[4, 14]. Z tego powodu w pracy nie wykorzystano bezpośrednio idealnej wartości glikemii generowanej przez model Bergmana, lecz wprowadzono dodatkowy model systemu pomiarowego CGM. Pozwala to lepiej odwzorować warunki pracy rzeczywistego systemu zamkniętej pętli.

W pracy przyjęto, że rzeczywisty poziom glukozy $G(t)$, wyznaczany przez model fizjologiczny pacjenta, nie jest bezpośrednio dostępny dla regulatora. Zamiast tego regulator może korzystać z wartości mierzonej przez sensor CGM, którą można zapisać w uproszczonej postaci:

$$\text{CGM}(t) = G(t - \tau) + \eta(t) + d(t) \quad (2.2)$$

gdzie:

$\text{CGM}(t)$ – wartość glukozy mierzona przez sensor,

$G(t - \tau)$ – rzeczywista glikemia opóźniona o czas τ ,

τ – opóźnienie pomiarowe sensora,

$\eta(t)$ – losowy szum pomiarowy,

$d(t)$ – dryft sensora w czasie.

Należy podkreślić, że zastosowany model CGM jest uproszczeniem. Nie uwzględnia on wszystkich zjawisk charakterystycznych dla rzeczywistych sensorów, takich jak chwilowe zaniki sygnału, błędy kalibracji zależne od poziomu glukozy, kompresyjne hipoglikemie czy różnice pomiędzy konkretnymi modelami urządzeń. Mimo to model

ten jest wystarczający do celów niniejszej pracy, ponieważ pozwala odwzorować trzy najważniejsze cechy sygnału CGM z punktu widzenia sterowania: opóźnienie, szum oraz dryft.

Tak zdefiniowany model systemu pomiarowego stanowi pośredni element pomiędzy modelem fizjologicznym pacjenta a algorytmem sterującym. Dzięki niemu badane regulatory nie działają w warunkach idealnych, lecz muszą podejmować decyzje na podstawie danych zbliżonych do tych, które występują w rzeczywistych systemach zamkniętej pętli.

2.3 Regulator PID

Regulator PID (ang. *Proportional-Integral-Derivative*) jest jednym z najczęściej stosowanych algorytmów sterujących w automatyce przemysłowej. Jego popularność wynika z prostoty implementacji, niewielkich wymagań obliczeniowych oraz dobrej skuteczności w sterowaniu układami dynamicznymi [7]. Regulatory PID od wielu lat wykorzystywane są m.in. w układach regulacji temperatury, ciśnienia, prędkości obrotowej silników czy procesach chemicznych. Ze względu na swoją uniwersalność znalazły również zastosowanie w medycynie [12, 27]. Zadaniem regulatora jest automatyczne wyznaczanie dawki insuliny na podstawie aktualnego poziomu glukozy tak, aby utrzymać glikemię możliwie blisko wartości docelowej.

W niniejszej pracy regulator PID został wykorzystany jako podstawowy algorytm sterowania w systemie zamkniętej pętli opartym na modelu Bergmana. Wybrano go ze względu na:

- prostotę matematyczną,
- możliwość działania w czasie rzeczywistym
- niewielkie wymagania obliczeniowe,
- łatwość interpretacji działania.

Regulator PID stanowi również istotny punkt odniesienia dla bardziej zaawansowanych metod sterowania, takich jak MPC (ang. *Model Predictive Control*) oraz algorytm uczenia ze wzmocnieniem (ang. *Reinforcement Learning*).

2.3.1 Działanie regulatora

Działanie regulatora PID opiera się na analizie błędu regulacji, zdefiniowanego jako różnica pomiędzy wartością docelową glukozy a jej aktualnym poziomem:

$$e(t) = G_{\text{target}} - G(t) \quad (2.3)$$

gdzie:

$G(t)$ – aktualny poziom glukozy,

G_{target} – wartość docelowa glikemii,

$e(t)$ – błąd regulacji.

Sygnal sterujący, wyznaczający dawkę insuliny, opisuje równanie regulatora PID [7, 27]:

$$u(t) = K_P e(t) + K_I \int_0^t e(\xi) d\xi + K_D \frac{de(t)}{dt} \quad (2.4)$$

gdzie:

$u(t)$ – sygnał sterujący odpowiadający dawce insuliny,

K_P – wzmacnienie członu proporcjonalnego,

K_I – wzmacnienie członu całkującego,

K_D – wzmacnienie członu różniczkującego.

2.3.2 Człon proporcjonalny

Człon proporcjonalny P reaguje bezpośrednio na aktualny błąd regulacji. Im większe odchylenie glikemii od wartości docelowej, tym większa dawka insuliny zostaje podana przez regulator. Składnik ten odpowiada za szybką reakcję układu na hiperglikemię. Może ono jednak prowadzić do oscylacji glukozy i niestabilności układu.

2.3.3 Człon całkujący

Człon całkujący I analizuje skumulowany błąd z przeszłości i odpowiada za eliminację błędu ustalonego. W przypadku systemów diabetologicznych ma on szczególne znaczenie, ponieważ działanie insuliny jest opóźnione i rozciągnięte w czasie. Jednocześnie człon całkujący może prowadzić do zjawiska “integral wind-up”, polegającego na nadmiernym narastaniu całki podczas długotrwałego błędu regulacji. W praktyce skutkuje to podaniem zbyt dużej ilości insuliny i ryzykiem hipoglikemii. Podczas implementacji regulatora w niniejszej pracy zaobserwowano takie zjawisko po zwiększeniu wrażliwości na insulinę. Nawet niewielki wzrost podaży insuliny prowadził wówczas do gwałtownego spadku glikemii. Z tego względu zastosowano mechanizm ograniczenia całki, ograniczając maksymalną wartość członu całkowitego.

2.3.4 Człon różniczkujący

Człon różniczkujący D odpowiada za analizę szybkości zmian glukozy. Pozwala przewidywać kierunek zmian glikemii i reagować jeszcze przed wystąpieniem dużego błędu regulacji. W systemach monitorowania glukozy człon ten jest jednak szczególnie podatny na zakłócenia wynikające z opóźnienia pomiarowego czy szumu sensora CGM. W praktyce zbyt duże wzmocnienie może prowadzić do niestabilności sterowania i nadmiernej reakcji na chwilowe błędy pomiarowe.

2.3.5 Zastosowanie PID

W literaturze dotyczącej sztucznej trzustki regulator PID jest często wykorzystywanym algorytmem sterowania. Jego skuteczność została potwierdzona szczególnie w scenariuszach stabilnych, bez dużych zakłóceń środowiskowych.

W praktyce jednak sterowanie glikemią jest znacznie trudniejsze niż klasyczne problemy regulacji przemysłowej. Organizm człowieka stanowi bowiem układ nieliniowy, zmienny w czasie, obciążony opóźnieniem, podatnym na zakłócenia.

Jednym z największych problemów regulatora jest konieczność odpowiedniego doboru parametrów K_p , K_i , K_d . Nieprawidłowe strojenie może prowadzić do [7, 12]:

- oscylacji glikemii,
- zbyt agresywnego dawkowania insuliny,
- opóźnienia reakcji regulatora,
- ciężkich hipoglikemii.

Pomimo swojej popularności regulator PID posiada ograniczenia w zastosowaniach diabetologicznych. Najważniejsze z nich to:

- ograniczona odporność na opóźnienia,
- trudność pracy z układami nieliniowymi,
- brak adaptacji do zmieniającej się fizjologii pacjenta,
- ryzyko hipoglikemii przy agresywnym sterowaniu.

Problemy te były widoczne podczas symulacji przeprowadzonych w niniejszej pracy, co zostanie pokazane w późniejszych działach.

2.4 Regulator MPC

Regulator modelowy MPC (ang. *Model Predictive Control*) należy do bardziej zaawansowanych metod sterowania. W przeciwieństwie do klasycznego regulatora PID, który reaguje głównie na bieżący stan układu, MPC wykorzystuje model matematyczny układu do przewidywania przyszłych zmian glikemii i podejmowania decyzji wyprzedzających[15, 19].

W niniejszej pracy regulator MPC został wybrany jako bardziej zaawansowana alternatywa dla regulatora PID. Szczególnie istotna była możliwość uwzględnienia dynamiki modelu Bergmana, opóźnień działania insuliny oraz ograniczeń dawkowania występujących w rzeczywistych systemach diabetologicznych.

Podstawową ideą regulatora MPC jest wykorzystanie modelu matematycznego organizmu do przewidywania przyszłych wartości glukozy w określonym horyzoncie czasowym[15, 3].

Algorytm działa cyklicznie wg następującego schematu:

1. Odczyt aktualnego poziomu glukozy z systemu CGM.
2. Wykorzystanie modelu matematycznego do przewidzenia przyszłego przebiegu glikemii.
3. Wyznaczenie optymalnej sekwencji podaży insuliny minimalizującej funkcję kosztu.
4. Podanie jedynie pierwszej dawki z obliczonej sekwencji.
5. Powtórzenie całego procesu po otrzymaniu kolejnego pomiaru

Dzięki temu regulator stale aktualizuje swoje decyzje na podstawie nowych danych pomiarowych.

W przeciwieństwie do regulatora PID, MPC nie reaguje wyłącznie na aktualny błąd, lecz przewiduje przyszłe zachowanie układu. Pozwala to na wcześniejsze przeciwdziałanie hiperglikemii lub hipoglikemii oraz lepsze uwzględnienie opóźnień charakterystycznych dla systemów diabetologicznych[3, 10].

2.4.1 Model predykcyjny

Kluczowym elementem regulatora MPC jest model matematyczny opisujący dynamikę glukozy i insuliny. W niniejszej pracy rolę modelu predykcyjnego pełnił dyskretny model Bergmana opisujący zależności pomiędzy poziomem glukozy, aktywnością insuliny i podażą insuliny, co pozwala na przewidywanie zmian glikemii w kolejnych krokach symulacji.

2.4.2 Funkcja kosztu

Regulator MPC wyznacza sterowanie poprzez minimalizację funkcji kosztu opisującej jakość regulacji. Typowa funkcja kosztu zawiera:

- błąd pomiędzy przewidywaną glikemią a wartością docelową,
- karę za zbyt duże dawki insuliny,
- karę za gwałtowne zmiany sterowania.

$$J = \sum (G_{\text{pred}} - G_{\text{target}})^2 + \lambda \sum U^2 \quad (2.5)$$

gdzie:

G_{pred} – przewidywana glikemia,

G_{target} – wartość docelowa glikemii,

U – dawka insuliny,

λ – współczynnik ograniczający agresywność sterowania.

Minimalizacja funkcji kosztu pozwala regulatorowi znaleźć kompromis pomiędzy szybkim obniżaniem glukozy a bezpieczeństwem terapii.

2.4.3 Horyzont predykcji i horyzont sterowania

Horyzont predykcji określa, jak daleko w przyszłość regulator przewiduje zachowanie glikemii. Horyzont sterowania definiuje natomiast liczbę przyszłych kroków, dla których wyznaczone są dawki insuliny.

Dłuższy horyzont predykcji pozwala lepiej uwzględnić opóźnione działanie insuliny oraz wpływ posiłków, jednak zwiększa złożoność obliczeniową algorytmu. Zbyt długi horyzont może również prowadzić do większych błędów predykcji wynikających z niedokładności modelu.

2.4.4 Zalety MPC

Najważniejsze zalety regulatorów MPC obejmują:

- możliwość przewidywania przyszłych zmian glikemii,
- uwzględnianie opóźnień działania insuliny,

- możliwość narzucenia ograniczeń bezpieczeństwa,
- lepszą kontrolę po posiłkach,
- mniejsze ryzyko przeregulowania,
- większą stabilność układu.

Badania wskazują, że systemy oparte na MPC często osiągają wyższy parametr Time in Range niż klasyczne regulatory PID.

2.4.5 Ograniczenia MPC

Pomimo licznych zalet, regulator MPC posiada również istotne ograniczenia. Najważniejszym problemem jest zależność regulatora od jakości modelu matematycznego. Organizm człowieka stanowi układ silnie nieliniowy i zmienny w czasie, dlatego dokładne odwzorowanie pacjenta jest bardzo trudne. Do głównych ograniczeń MPC należą:

- duża złożoność obliczeniowa,
- konieczność rozwiązywania problemu optymalizacji w czasie rzeczywistym,
- zależność od jakości modelu predykcyjnego,
- trudność uwzględnienia wszystkich czynników wpływających na glikemię,
- problemy wynikające z niedokładności sensorów CGM.

2.5 Regulator oparty na uczeniu ze wzmocnieniem

Uczenie ze wzmocnieniem, określone skrótem RL (ang. *Reinforcement Learning*) jest jedną z metod uczenia maszynowego, w której algorytm uczy się podejmowania decyzji poprzez interakcję ze środowiskiem. W odróżnieniu od klasycznego uczenia nadzorowanego, gdzie model trenuje się na podstawie par wejście-oczekiwane wyjście, w uczeniu ze wzmocnieniem agent otrzymuje informację zwrotną w postaci nagrody lub kary. Celem procesu uczenia jest znalezienie takiej strategii działania, która maksymalizuje sumę nagród w dłuższym horyzoncie czasowym.

W kontekście automatycznego sterowania glikemią środowiskiem jest model organizmu pacjenta, stanem - aktualna sytuacja metaboliczna, akcją - dawka insuliny, natomiast nagroda odzwierciedla jakość utrzymania poziomu glukozy w zakresie docelowym. Takie podejście pozwala traktować sterowanie insuliną jako problem sekwencyjnego podejmowania decyzji, w którym każda podana dawka wpływa nie tylko na

aktualny poziom glukozy, ale również na przyszłe zachowanie układu. Przeglądy literatury wskazują, że RL jest intensywnie badane w kontekście systemów zamkniętej pętli, insulinoaterapii oraz spersonalizowanego wspomagania decyzji terapeutycznych[21, 24].

2.5.1 Podstawowe elementy uczenia ze wzmocnieniem

Model uczenia ze wzmocnieniem składa się z kilku podstawowych elementów:

- agent - algorytm podejmujący decyzje
- środowisko - model pacjenta
- stan - opis aktualnej sytuacji układu
- akcja - decyzja agenta, np. wielkość dawki insuliny
- nagroda - informacja oceniająca jakość decyzji
- polityka - strategia wyboru akcji w danym stanie.

W przypadku systemu automatycznego podawania insuliny stan może zawierać m.in. aktualną glikemię, trend zmian glukozy, wcześniejsze dawki insuliny lub przybliżenie aktywnej insuliny w organizmie. Akcją regulatora jest natomiast wielkość podaży insuliny w danym kroku czasowym. Funkcja nagrody powinna promować utrzymywanie glikemii w zakresie docelowym oraz silnie karać sytuacje niebezpieczne, szczególnie hipoglikemię.

Dobrze zaprojektowana funkcja nagrody jest jednym z najważniejszych elementów regulatora RL. Zbyt słaba kara za hipoglikemię może prowadzić do agresywnego dawkowania insuliny, natomiast zbyt duża kara za hiperglikemię może powodować nadmierne reakcje regulatora. W praktyce funkcja nagrody powinna uwzględniać nie tylko odchylenie glukozy od wartości docelowej, ale również bezpieczeństwo terapii, ograniczenie gwałtownych zmian dawki oraz ilość zużytej insuliny.

2.5.2 Zastosowanie RL w sterowaniu glikemią

Sterowanie glikemią jest problemem szczególnie odpowiednim do analizy za pomocą uczenia ze wzmocnieniem, ponieważ decyzje terapeutyczne mają charakter sekwencyjny. Podana insulina działa z opóźnieniem, a jej efekt może utrzymywać się przez kilka godzin. Oznacza to, że decyzja podjęta w danym momencie wpływa na przyszłe wartości glikemii i może zwiększać lub zmniejszać ryzyko późniejszej hipoglikemii.

W przeciwieństwie do regulatora PID, który reaguje głównie na aktualny błąd, oraz MPC, który wymaga jawnego modelu predykcyjnego, regulator RL może uczyć

się strategii sterowania na podstawie interakcji ze środowiskiem. Pozwala to potencjalnie lepiej dostosować działanie regulatora do nieliniowych zależności między glukozą, insuliną, aktywnością fizyczną oraz innymi czynnikami wpływającymi na metabolizm. Badania nad głębokim uczeniem ze wzmocnieniem wskazują, że takie podejście może być wykorzystane zarówno w jednorodnych systemach podawania insuliny, jak i w systemach dwuhormonalnych obejmujących insulinę oraz glukagon [24, 28].

2.5.3 Wybór metody uczenia

W prostych problemach RL często stosuje się klasyczny Q-learning lub jego głęboką wersję DQN (Deep Q-Network). Metody te dobrze sprawdzają się wtedy, gdy przestrzeń akcji jest dyskretna, tzn. agent wybiera jedną z kilku możliwych decyzji. W przypadku sterowania pompą insulinową naturalniejszym podejściem jest jednak traktowanie dawki insuliny jako wartości ciągłej. Pompa może bowiem podawać insulinę w różnych dawkach, a ograniczanie decyzji do kilku sztywnych poziomów mogłoby zmniejszyć precyzję sterowania.

Z tego względu w pracy przyjęto podejście typu *actor-critic*, w którym wykorzystywane są dwie sieci neuronowe: aktor oraz krytyk. Aktor odpowiada za wyznaczanie akcji, czyli dawki insuliny, natomiast krytyk ocenia jakość tej decyzji na podstawie przewidywanej przyszłej nagrody. Taka struktura jest typowa dla metod przeznaczonych do sterowania w przestrzeniach ciągłych, takich jak DDPG (ang. *Deep Deterministic Policy Gradient*). Algorytm DDPG został zaproponowany jako metoda umożliwiająca uczenie polityki sterowania w problemach, w których akcje mają charakter ciągły.

W kontekście niniejszej pracy wybór podejścia *actor-critic* wynika z faktu, że regulator ma wyznaczać ciągłą wartość podaży insuliny, a nie wybierać jedną z kilku z góry zdefiniowanych decyzji. Jest to bliższe rzeczywistemu działaniu pompy insulinowej, która może modyfikować tempo infuzji w sposób płynny.

2.5.4 Zasada działania regulatora RL

Regulator oparty na uczeniu ze wzmocnieniem działa w kolejnych krokach czasowych. W każdym kroku agent otrzymuje obserwację stanu układu, na przykład aktualny poziom glukozy, trend zmian oraz informację o wcześniejszej podaży insuliny. Na tej podstawie wybiera akcję, czyli dawkę insuliny. Następnie środowisko, reprezentujące organizm pacjenta, przechodzi do nowego stanu, a agent otrzymuje nagrodę zależną od jakości podjętej decyzji.

W uproszczeniu proces ten można opisać następująco:

$$s_t \rightarrow a_t \rightarrow r_t \rightarrow s_{t+1} \tag{2.6}$$

gdzie:

s_t – stan układu w chwili t ,

a_t – akcja wybrana przez regulator,

r_t – nagroda,

s_{t+1} – kolejny stan układu.

Celem agenta jest znalezienie takiej polityki $\pi(s)$, która dla danego stanu wybiera akcję maksymalizującą oczekiwaną sumę przyszłych nagród. W systemie sterowania glikemią oznacza to nauczenie się takiego dawkowania insuliny, które nie tylko obniża aktualną hiperglikemię, ale również ogranicza ryzyko późniejszej hipoglikemii.

2.5.5 Zalety regulatorów RL

Najważniejszą zaletą regulatorów opartych na uczeniu ze wzmocnieniem jest ich zdolność do uczenia się złożonych, nieliniowych zależności. W przeciwieństwie do PID regulator RL nie musi ograniczać się do prostych zależności między błędem a sterowaniem. W przeciwieństwie do klasycznego MPC nie musi także korzystać z jawnie zdefiniowanego modelu predykcyjnego, chociaż w praktyce proces uczenia zazwyczaj odbywa się w symulatorze.

Do głównych zalet regulatorów RL należą:

- możliwość uczenia się strategii sterowania na podstawie doświadczenia,
- zdolność do modelowania nieliniowych zależności,
- potencjalna adaptacja do indywidualnych cech pacjenta,
- możliwość uwzględniania wielu źródeł danych,
- elastyczność w definiowaniu celu sterowania poprzez funkcję nagrody.

Szczególnie istotna jest możliwość personalizacji, ponieważ zapotrzebowanie na insulinę różni się między pacjentami, a nawet u tej samej osoby zmienia się w czasie pod wpływem aktywności fizycznej, stresu, hormonów czy choroby. W literaturze podkreśla się, że metody RL mogą być szczególnie interesujące jako kierunek rozwoju bardziej adaptacyjnych systemów sztucznej trzustki.

2.5.6 Ograniczenia i ryzyka

Pomimo dużego potencjału, zastosowanie RL w systemach automatycznego podawania insuliny wiąże się z istotnymi ograniczeniami. Najważniejszym problemem jest bezpieczeństwo procesu uczenia. Agent RL uczy się metodą prób i błędów, co w przypadku rzeczywistego pacjenta byłoby niedopuszczalne. Z tego względu trening musi odbywać się w środowisku symulacyjnym lub na danych historycznych, a dopiero wytrenowany model może być oceniany pod kątem bezpieczeństwa.

Drugim istotnym problemem jest trudność interpretacji decyzji podejmowanych przez sieci neuronowe. W regulatorze PID wpływ parametrów jest stosunkowo łatwy do zrozumienia, a w MPC decyzje wynikają z jawnej funkcji kosztu. W przypadku RL polityka sterowania może być trudniejsza do wyjaśnienia, co stanowi wyzwanie w zastosowaniach medycznych.

Do najważniejszych ograniczeń regulatorów RL należą:

- konieczność treningu w symulatorze,
- duża liczba wymaganych epizodów uczenia,
- ryzyko nauczenia się strategii niestabilnych lub niebezpiecznych,
- wrażliwość na definicję funkcji nagrody,
- trudność interpretacji działania modelu,
- problem przeniesienia polityki z symulacji do rzeczywistości.

Nowsze prace wskazują, że choć głębokie RL ma duży potencjał w systemach sztucznej trzustki, to głównymi barierami pozostają bezpieczeństwo, efektywność treningu oraz walidacja kliniczna[29].

Rozdział 3

Przebieg badania

3.1 Środowisko badawcze i narzędzia

Badania symulacyjne przeprowadzono w środowisku Jupyter Notebook z wykorzystaniem języka Python w wersji 3.11.0. Wybór tego środowiska wynikał z potrzeby prowadzenia eksperymentów iteracyjnych, w których kolejne etapy modelowania, symulacji, wizualizacji oraz analizy wyników mogą być wykonywane i modyfikowane w sposób interaktywny. Jupyter Notebook umożliwia łączenie kodu źródłowego, wyników obliczeń, wykresów oraz komentarzy opisowych w jednym pliku, co jest szczególnie przydatne podczas prowadzenia badań symulacyjnych.

Biblioteka NumPy została wykorzystana do obliczeń numerycznych, tworzenia wektorów czasowych oraz przechowywania przebiegów zmiennych stanu modelu. Biblioteka Pandas posłużyła do organizacji wyników symulacji w postaci tabelarycznej, co ułatwia późniejsze obliczenia. Do wizualizacji wyników zastosowano bibliotekę Matplotlib.

W części pracy dotyczącej regulatora opartego na uczeniu ze wzmocnieniem wykorzystano dodatkowo bibliotekę PyTorch, służącą do tworzenia, trenowania oraz optymalizacji sieci neuronowych. Biblioteka ta została użyta do implementacji struktur aktora i krytyka, stanowiących podstawę zastosowanego podejścia *actor-critic*. Ponadto w implementacji wykorzystano moduły pomocnicze języka Python, takie jak *random* oraz *collection.deque*. Moduł *random* umożliwił losowe próbkowanie doświadczeń podczas procesu uczenia, natomiast struktura *deque* została zastosowana jako bufor pamięci, w którym przechowywano doświadczenia agenta w postaci przejść między kolejnymi stanami środowiska.

3.1.1 Parametry symulacji

Symulację przeprowadzono w dyskretnych krokach czasowych. Przyjęto krok równy 5 minut, co odpowiada typowej częstotliwości zapisu danych w systemach CGM oraz

naturalnemu interwałowi działania regulatorów w systemach zamkniętej pętli.

```

1     delta_min = 5
2     T_hours = 12
3     steps = int((T_hours * 60) / delta_min)
4     G_target = 100.0

```

Listing 3.1: Parametry symulacji

Parametr δ_{min} określa długość pojedynczego kroku symulacji, natomiast T_{hours} oznacza całkowity czas trwania symulacji. Na tej podstawie obliczana jest liczba kroków $steps$. W analizowanym przypadku jedna symulacja obejmuje 12 godzin, co przy kroku 5-minutowym daje 144 punkty pomiarowe.

Wartość G_{target} oznacza docelowy poziom glukozy, do którego w dalszych częściach pracy będą dążyć regulatory PID, MPC oraz RL.

Parametry modelu Bergmana zostały zdefiniowane w słowniku:

```

1
2     params = {
3         "G_b": 280.0,
4         "I_b": 0.0,
5         "p1": 0.015,
6         "p2": 0.025,
7         "p3": 0.0006,
8         "n": 0.1,
9         "Vg": 0.6,
10        "Vi": 0.12,
11    }

```

Listing 3.2: Parametry modelu Bergmana

Przyjęte wartości mają charakter symulacyjny i zostały dobrane tak, aby model odwzorowywał uproszczony organizm osoby chorej na cukrzycę typu 1. Najważniejszym założeniem jest brak własnej produkcji insuliny, dlatego parametr I_b przyjmuje wartość 0.

Parametr G_b ustawiono na 280 mg/dL. Nie oznacza on w tym przypadku prawidłowej glikemii bazowej, lecz poziom, do którego układ dąży przy braku skutecznego działania insuliny. Takie ustawienie pozwala odwzorować stan przewlekłej hiperglikemii wynikający z braku endogennej insuliny oraz z obecności procesów zwiększających glikemię, takich jak uwalnianie glukozy przez wątrobę.

3.1.2 Implementacja modelu Bergmana

Podstawą środowiska symulacyjnego jest uproszczony, dyskretny model Bergmana opisujący zależność pomiędzy glukozą, insuliną oraz opóźnionym działaniem insuliny w organizmie. Model został zaadaptowany do przypadku chorej na cukrzycę typu 1.

```

1
2     def simulate_bergman_discrete(params, delta_min, steps, Ra,
3       U, G_start=90.0, noise_std_G=0.0):
4
5         dt = delta_min
6         times = np.arange(0, steps * dt, dt)
7         G = np.zeros(steps)
8         X = np.zeros(steps)
9         I = np.zeros(steps)
10        G[0] = G_start
11        X[0] = 0.0
12        I[0] = params["I_b"]
13        for k in range(steps - 1):
14            g = G[k]
15            x = X[k]
16            i = I[k]
17            ra_k = Ra[k]
18            u_k = U[k]
19            dG = -params["p1"] * (g - params["G_b"]) - x * g +
20                  (1.0 / params["Vg"]) * ra_k
21            dX = -params["p2"] * x + params["p3"] * (i - params
22                  ["I_b"])
23            dI = -params["n"] * i + (1 / params["Vi"]) * U[k]
24            G[k+1] = g + dt * dG + np.random.normal(0.0,
25                  noise_std_G)
26            X[k+1] = x + dt * dX
27            I[k+1] = i + dt * dI
28            if G[k+1] < 20.0:
29                G[k+1] = 20.0
30        df = pd.DataFrame({
31            "time_min": times,
32            "G": G,
33            "X": X,
34            "I": I,
35            "Ra": Ra[:steps],

```

```

32         "U": U[:steps],
33     })
34     return df

```

Listing 3.3: Implementacja modelu Bergmana

Funkcja przyjmuje jako argumenty parametry modelu, krok czasowy, liczbę kroków symulacji, profil wchłaniania glukozy R_a , profil podaży insuliny U oraz początkowy poziom glukozy G_{start} .

W każdym kroku czasowym obliczane są przyrosty trzech zmiennych: glukozy, działania insuliny oraz insuliny w organizmie. Zastosowano dyskretyzację metodą Eulera, w której kolejna wartość zmiennej wyznaczana jest na podstawie jej aktualnej wartości oraz obliczonej pochodnej.

Równanie glukozy ma postać:

$$\frac{dG}{dt} = -p_1(G - G_b) - XG + \frac{1}{V_g}R_a(t) \quad (3.1)$$

Pierwszy składnik opisuje dążenie glukozy do poziomu równowagi. W modelu osoby chorej na cukrzycę typu 1 wartość ta została ustawiona na poziomie hiperglikemicznym, co odpowiada sytuacji, w której organizm bez insuliny dąży do utrzymywania podwyższonego poziomu glukozy. Drugi składnik opisuje obniżanie glukozy pod wpływem działania insuliny. Trzeci składnik odpowiada za wzrost glukozy wynikający z pojawienia się glukozy po posiłku.

Równanie zmiennej X , opisującej opóźnione działanie insuliny, ma postać:

$$\frac{dX}{dt} = -p_2X + p_3(I - I_b) \quad (3.2)$$

Parametr p_2 odpowiada za tempo zaniku działania insuliny, natomiast p_3 określa wrażliwość organizmu na insulinę. Im większa wartość p_3 , tym silniejszy wpływ insuliny na obniżanie glikemii.

Równanie insuliny ma postać:

$$\frac{dI}{dt} = -nI + \frac{1}{V_i}U(t) \quad (3.3)$$

Ponieważ model dotyczy cukrzycy typu 1, przyjęto brak endogennej produkcji insuliny. Oznacza to, że insulina obecna w organizmie pochodzi wyłącznie z zewnętrznej podaży, reprezentowanej przez sygnał U .

3.1.3 Model pojawiania się glukozy po posiłku

W celu umożliwienia symulacji scenariuszy z posiłkiem zaimplementowano funkcję generującą profil pojawiania się glukozy $R_a(t)$.

```
1
2  def meal_ra_profile(total_carbs_g, t0_min, time_vector_min,
3                        tau_rise=30, tau_decay=90):
4
5      t = np.array(time_vector_min)
6      ra = np.zeros_like(t, dtype=float)
7      if total_carbs_g <= 0:
8          return ra
9      scale = 0.05
10     amplitude = total_carbs_g * scale
11     for i, ti in enumerate(t):
12         dt = ti - t0_min
13         if dt >= 0:
14             ra[i] = amplitude * (dt / (tau_rise + 1e-9)) *
15                 np.exp(1 - dt / tau_decay)
16             if ra[i] < 0:
17                 ra[i] = 0.0
18     return ra
```

Listing 3.4: Model pojawiania się glukozy po posiłku

Funkcja ta odwzorowuje wzrost glukozy po spożyciu węglowodanów. Parametr *total_carbs_g* oznacza ilość spożytych węglowodanów, natomiast *t0_min* określa moment posiłku. Parametry *tau_rise* i *tau_decay* odpowiadają za kształt krzywej wchłaniania: pierwszy opisuje szybkość narastania, a drugi tempo wygaszania efektu posiłku.

Dzięki temu możliwe jest modelowanie sytuacji, w której po posiłku poziom glukozy nie wzrasta natychmiastowo, lecz stopniowo, osiągając maksimum po pewnym czasie, a następnie powoli zanika.

3.1.4 Model systemu CGM

W rzeczywistych systemach zamkniętej pętli regulator nie korzysta z idealnej wartości glikemii, lecz z pomiaru dostarczanego przez sensor CGM. Dlatego w środowisku badawczym zaimplementowano dodatkowy model systemu pomiarowego CGM:

```
1  def generate_cgm_from_true(G_series, delay_min=15,
2                                noise_std=1.0, drift_per_hour=0.0, delta_min=5):
```

```
3     steps = len(G_series)
4     delay_steps = int(delay_min / delta_min)
5     cgm = np.zeros(steps)
6     for k in range(steps):
7         idx = max(0, k - delay_steps)
8         base = G_series[idx]
9         noise = np.random.normal(0.0, noise_std)
10        drift = (k * delta_min / 60.0) * drift_per_hour
11        cgm[k] = base + noise + drift
12    return cgm
```

Listing 3.5: Model systemu CGM

Model CGM uwzględnia trzy zjawiska charakterystyczne dla rzeczywistych sensorów:

- opóźnienie pomiarowe,
- szum losowy,
- dryft sensora.

Opóźnienie wynika z faktu, że sensor CGM mierzy poziom glukozy w płynie śródtkankowym, a nie bezpośrednio we krwi. W implementacji efekt ten uzyskano poprzez wykorzystanie wcześniejszej wartości glukozy $G_{\text{series}[idx]}$, przesuniętej o liczbę kroków odpowiadającą opóźnieniu *delay_min*.

Szum losowy modeluje niepewność pomiarową sensora i generowany jest z rozkładu normalnego. Dryft opisuje natomiast powolne, systematyczne odchylenie pomiaru narastające w czasie.

W badaniu bazowym zastosowano następujące ustawienia:


```
1     df["CGM"] = generate_cgm_from_true(
2         df["G"].values,
3         delay_min=15,
4         noise_std=2.0,
5         drift_per_hour=0.2,
6         delta_min=delta_min
7     )
```

Listing 3.6: Parametry modelu CGM

Oznacza to, że odczyt CGM jest opóźniony o 15 minut, zawiera niewielki szum losowy $noise_std = 2.0$ oraz powolny dryft wynoszący 0,2 mg/dL na godzinę.

3.1.5 Symulacja modelu bez udziału regulatora

Po zdefiniowaniu modelu fizjologicznego, profilu posiłku oraz modelu CGM przeprowadzono symulację bazową bez udziału regulatora. Celem tej symulacji było sprawdzenie zachowania modelu pacjenta w warunkach braku posiłku oraz braku zewnętrznej podaży insuliny.



Rysunek 3.1: Symulacja modelu Bergmana bez regulatora.

W analizowanym scenariuszu glikemia początkowa wynosi 90 mg/dL, czyli znajduje się w zakresie prawidłowym. Ponieważ jednak model reprezentuje osobę chorą na cukrzycę typu 1, a zewnętrzna podaż insuliny jest wyłączona, poziom glukozy stopniowo rośnie i dąży do wartości równowagi hiperglikemicznej określonej parametrem G_b .

Na wykresie przedstawiono dwa przebiegi:

- G_{true} - rzeczywisty poziom glukozy generowany przez model Bergmana,
- CGM - odczyt sensora CGM, uwzględniający opóźnienie, szum i dryft.

3.2 Scenariusze badawcze

W celu oceny działania poszczególnych algorytmów, opracowane zostały różne scenariusze odzwierciedlające typowe sytuacje, z którymi pacjenci spotykają się w życiu codziennym. Zostały one dobrane tak, aby umożliwić sprawdzenie działania regulatorów zarówno w warunkach stabilnych, jak i w obecności dynamicznych zakłóceń wpływających na poziom glukozy.

W badaniach uwzględniono następujące przypadki:

- Scenariusz A - brak posiłku, brak wysiłku fizycznego, brak istotnych zakłóceń,
- Scenariusz B - wystąpienie posiłku powodującego wzrost glikemii,
- Scenariusz C - wysiłek fizyczny powodujący zmianę wrażliwości insulinowej,
- Scenariusz D - zakłócenia pomiaru CGM.

Każdy scenariusz został przeprowadzony dla trzech regulatorów: PID, MPC, RL. Wyniki przedstawiono w postaci wykresów glikemii, odczytów CGM oraz podaży insuliny. W rozdziale tym zaprezentowano przebieg eksperymentów i omówiono zachowanie poszczególnych regulatorów w każdym scenariuszu.

3.3 Scenariusz A i implementacja regulatorów

Celem pierwszego scenariusza było sprawdzenie, czy regulator jest w stanie utrzymać lub przywrócić glikemię do wartości docelowej w warunkach podstawowych, bez dodatku zakłóceń. Scenariusz ten stanowi punkt odniesienia dla kolejnych eksperymentów, ponieważ pozwala ocenić podstawową stabilność układu.

W scenariuszu A założono:

- brak posiłku,
- brak wysiłku fizycznego,
- standardowy odczyt CGM.

W przypadku symulacji bez regulatora glikemia stopniowo wzrastała w kierunku hiperglikemii określonej parametrem G_b . Dla regulatorów oczekiwanym działaniem jest wygenerowanie takiej podaży insuliny, aby glikemia została sprowadzona do zakresu docelowego i utrzymywała się w nim przez możliwie długi czas.

3.3.1 Regulator PID

Regulator został zaimplementowany zgodnie z klasyczną strukturą PID, w której sygnał sterujący zależy od trzech składników: proporcjonalnego, całkującego oraz różniczkującego. Błąd regulacji wyznaczono jako różnicę między aktualnym odczytem CGM a wartością docelową glikemii:

$$e(t) = \text{CGM}(t) - G_{\text{target}} \quad (3.4)$$

Na tej podstawie regulator oblicza dawkę insuliny zgodnie z równaniem:

$$U(t) = K_p e(t) + K_i \int_0^t e(\xi) d\xi + K_d \frac{de(t)}{dt} \quad (3.5)$$

W implementacji zastosowano również ograniczenie maksymalnej dawki insuliny oraz mechanizm *wind-up*, który zapobiega nadmiernemu narastaniu członu całkującego w sytuacji osiągnięcia ograniczenia sygnału sterującego. Jest to istotne, ponieważ zbyt duża wartość członu całkującego mogłaby prowadzić do nadmiernego podania insuliny i wystąpienia hipoglikemii.

```

1  def pid_controller(G_measured, G_target, dt, Kp, Ki, Kd,
2      integral_prev, error_prev, max_U=0.1):
3
4      error = G_measured - G_target
5      integral = integral_prev + error * dt
6      integral = max(min(integral, 10000), -10000)
7
8      derivative = (error - error_prev) / dt
9
10     U = Kp * error + Ki * integral + Kd * derivative
11
12     U_sat = max(0.0, min(U, max_U))
13     if U != U_sat:
14         integral = integral_prev
15
16     return U_sat, integral, error

```

Listing 3.7: Implementacja regulatora PID

Do przeprowadzenia eksperymentu wykorzystano funkcję *simulate_pid_a*, która łączy w jednej pętli trzy elementy: model Bergmana, model pomiarowy CGM oraz regulator PID. W każdej iteracji najpierw generowany jest opóźniony i zaszumiony odczyt CGM, następnie regulator wyznacza dawkę insuliny, a na końcu aktualizowany jest stan pacjenta w modelu Bergmana.

```

1  def simulate_pid_a(params, Kp, Ki, Kd, delay_min=15,
2      noise_std=2.0, drift_per_hour=0.2):
3
4      dt = delta_min
5      times = np.arange(0, steps * dt, dt)
6      delay_steps = int(delay_min / dt)
7
8      G = np.zeros(steps)

```

```

7      X = np.zeros(steps)
8      I = np.zeros(steps)
9      U = np.zeros(steps)
10     CGM = np.zeros(steps)
11
12     G[0] = 90.0
13     X[0] = 0.0
14     I[0] = 0.0
15
16     integral = 0.0
17     error_prev = 0.0
18
19     for k in range(steps - 1):
20         idx_delayed = max(0, k - delay_steps)
21         noise = np.random.normal(0.0, noise_std)
22         drift = (k * dt / 60.0) * drift_per_hour
23         CGM[k] = G[idx_delayed] + noise + drift
24
25         U[k], integral, error_prev = pid_controller(
26             CGM[k], G_target, dt, Kp, Ki, Kd, integral,
27             error_prev
28         )
29
30         g, x, i = G[k], X[k], I[k]
31
32         dG = -params["p1"] * (g - params["G_b"]) - x * g
33         dX = -params["p2"] * x + params["p3"] * i
34         dI = -params["n"] * i + (1 / params["Vi"]) * U[k]
35
36         G[k+1] = g + dt * dG
37         X[k+1] = x + dt * dX
38         I[k+1] = i + dt * dI
39
40     CGM[-1] = G[max(0, (steps-1)-delay_steps)] + np.random.
41         normal(0.0, noise_std)
42
43     return pd.DataFrame({"time_min": times, "G": G, "CGM":
44         CGM, "U": U})

```

Listing 3.8: Symulacja regulatora PID dla scenariusza A

Symulację przeprowadzono z następującymi wartościami parametrów regulatora:


```

1  Kp = 0.0004
2  Ki = 0.000005
3  Kd = 0.008
4  G_target = 100

```

Listing 3.9: Parametry regulatora PID

Wartości parametrów dobrano eksperymentalnie tak, aby regulator był w stanie obniżyć glikemię bez wywoływania ciężkiej hipoglikemii oraz bez nadmiernych oscylacji w stanie ustalonym.



Rysunek 3.2: Symulacja regulatora PID dla scenariusza A.

W początkowej fazie symulacji poziom glukozy wzrasta z wartości początkowej. Regulator PID reaguje dopiero na wzrost widoczny w odczytach CGM, które są opóźnione względem rzeczywistej glikemii.

Po wykryciu wzrostu glukozy regulator zwiększa podaż insuliny. Widoczny jest początkowy pik dawki, który prowadzi do szybkiego obniżenia glikemii. W wyniku opóźnienia pomiaru CGM oraz opóźnionego działania insuliny występuje jednak prze-regulowanie - glukoza spada poniżej wartości docelowej, zbliżając się do dolnej granicy zakresu terapeutycznego. Nie dochodzi jednak do ciężkiej hipoglikemii, co oznacza, że zastosowane ograniczenia sygnału sterującego oraz mechanizm anti-windup spełniają funkcję zabezpieczającą.

W dalszej części symulacji przebieg glukozy stabilizuje się w pobliżu wartości docelowej. Odczyty CGM pozostają nieco zaszumione, co przekłada się na widoczne wahania dawki insuliny. Jest to typowe zachowanie regulatora PID, zwłaszcza przy

obecności członu różniczkującego, który jest wrażliwy na zmiany i szумы w sygnale pomiarowym.

W scenariuszu A regulator PID spełnił swoje podstawowe zadanie - doprowadził glikemię do zakresu docelowego i utrzymywał ją w nim przez większość czasu symulacji. Największe odchylenia wystąpiły w początkowej fazie, gdy regulator musiał skompensować wzrost glukozy wynikający z braku endogennej insuliny.

Zaletą regulatora PID w tym scenariuszu była szybka reakcja na narastającą hiperglikemię oraz zdolność stabilizacji glikemii po fazie przejściowej. Jednocześnie wynik pokazuje ograniczenia tego podejścia: regulator nie przewiduje przyszłych zmian glukozy, lecz reaguje dopiero na aktualny błąd pomiarowy. W połączeniu z opóźnieniem CGM i opóźnionym działaniem insuliny może to prowadzić do przeregulowania oraz oscylacji.

Wahania sygnału insuliny w końcowej części symulacji wskazują również na wrażliwość regulatora PID na szum pomiarowy. Jest to szczególnie związane z członem różniczkującym, który reaguje na szybkie zmiany odczytu CGM. W praktycznych systemach problem ten może być ograniczany przez filtrację sygnału wejściowego lub zmniejszenie wartości współczynnika K_d .

3.3.2 Regulator MPC

W przeciwieństwie do regulatora PID, który reaguje bezpośrednio na bieżący błąd regulacji, MPC przewiduje przyszłe wartości glukozy w zadanym horyzoncie czasowym. W każdym kroku działania regulator analizuje możliwe dawki insuliny, symuluje ich wpływ na przyszły poziom glukozy i wybiera taką dawkę, która minimalizuje funkcję kosztu.

W implementacji wykorzystano funkcję *bergman_predict*, która służy do przewidywania kolejnego stanu pacjenta na podstawie modelu Bergmana:

```

1  def bergman_predict(y, u, params, dt):
2      G, X, I = y
3      dG = -params["p1"] * (G - params["G_b"]) - X * G
4      dX = -params["p2"] * X + params["p3"] * I
5      dI = -params["n"] * I + (1 / params["Vi"]) * u
6      return np.array([G + dG*dt, X + dX*dt, I + dI*dt])

```

Listing 3.10: Funkcja przewidywania stanu w regulatorze MPC

Funkcja przyjmuje aktualny stan modelu, dawkę insuliny oraz parametry pacjenta, a następnie zwraca przewidywany stan w kolejnym kroku. Dzięki temu regulator może oszacować, jak dana dawka insuliny wpłynie na poziom glukozy w najbliższej przyszłości.

Decyzja regulatora MPC opiera się na minimalizacji funkcji kosztu:

```

1
2  def cost_function(u_sequence, current_state_est, target_G,
3      params, horizon, dt, u_prev, lambda_u=10.0, lambda_du
4      =800.0):
5      cost = 0.0
6      temp_state = current_state_est.copy()
7
8      previous_u = u_prev
9
10     for u in u_sequence:
11         temp_state = bergman_predict(temp_state, u, params,
12             dt)
13         cost += (temp_state[0] - target_G) ** 2
14         cost += lambda_u * (u ** 2)
15         cost += lambda_du * ((u - previous_u) ** 2)
16         previous_u = u
17
18     return cost

```

Listing 3.11: Funkcja kosztu w regulatorze MPC

Pierwszy składnik funkcji kosztu odpowiada za utrzymywanie glikemii możliwie blisko wartości docelowej. Drugi składnik ogranicza nadmierną podaż insuliny. W ten sposób regulator dąży do kompromisu pomiędzy skutecznym obniżaniem glukozy a bezpieczeństwem sterowania.

Właściwa symulacja została przeprowadzona za pomocą funkcji *simulate_mpc_a*. W każdym kroku najpierw generowany jest odczyt CGM, następnie co 5 minut uruchamiany jest MPC, który wyznacza optymalną dawkę insuliny. Następnie aktualizowany jest zarówno przewidywany stan regulatora, jak i rzeczywisty stan pacjenta.

```

1  def simulate_mpc_scenario_a(params, lambda_u=10.0,
2      lambda_du=1300.0, max_delta_u=0.01):
3      dt_sim = 1.0
4      dt_mpc = 5.0
5      steps = int((12 * 60) / dt_sim)
6      times = np.arange(0, steps * dt_sim, dt_sim)
7
8      G = np.zeros(steps)
9      X = np.zeros(steps)
10     I = np.zeros(steps)

```

```

10     U = np.zeros(steps)
11     CGM = np.zeros(steps)
12
13     X_est = 0.0
14     I_est = 0.0
15     G[0] = 90.0
16     u_mpc = 0.013
17
18     delay_steps = int(15 / dt_sim)
19
20     for k in range(steps - 1):
21         idx_delayed = max(0, k - delay_steps)
22         CGM[k] = G[idx_delayed] + np.random.normal(0.0,
23             2.0)
24         if k % int(dt_mpc / dt_sim) == 0:
25             state_est = np.array([CGM[k], X_est, I_est])
26             u_init = np.full(12, u_mpc)
27             bounds = [(0.0, 0.1) for _ in range(12)]
28             res = minimize(
29                 cost_function,
30                 u_init,
31                 args=(state_est, G_target, params, 12,
32                     dt_mpc, u_mpc, lambda_u, lambda_du),
33                 bounds=bounds,
34                 method="L-BFGS-B"
35             )
36             u_new = res.x[0]
37             u_mpc = np.clip(
38                 u_new,
39                 u_mpc - max_delta_u,
40                 u_mpc + max_delta_u
41             )
42             u_mpc = float(np.clip(u_mpc, 0.0, 0.1))
43         U[k] = u_mpc
44
45         res_est = bergman_predict([CGM[k], X_est, I_est], U
46             [k], params, dt_sim)
47         X_est, I_est = res_est[1], res_est[2]
48
49         dG = -params["p1"] * (G[k] - params["G_b"]) - X[k]

```




```

47         * G[k]
48     dX = -params["p2"] * X[k] + params["p3"] * I[k]
49     dI = -params["n"] * I[k] + (1 / params["Vi"]) * U[k]
50     ]
51
52     G[k + 1] = G[k] + dt_sim * dG
53     X[k + 1] = X[k] + dt_sim * dX
54     I[k + 1] = I[k] + dt_sim * dI
55
56     CGM[-1] = CGM[-2]
57
58     return pd.DataFrame({
59         "time_min": times,
60         "G": G,
61         "CGM": CGM,
62         "U": U
63     })

```

Listing 3.12: Symulacja regulatora MPC dla scenariusza A

Do optymalizacji wykorzystano funkcję *minimize* z biblioteki *scipy.optimize*. Regulator przewiduje przebieg glikemii w horyzoncie 12 kroków, co przy kroku MPC równym 5 minut odpowiada jednej godzinie predykcji. Dla każdego kroku dawka insuliny jest ograniczona do zakresu od 0 do 0.1 j./min. Po rozwiązaniu problemu optymalizacji do układu podawana jest tylko pierwsza dawka z wyznaczonej sekwencji, a cały proces powtarzany jest przy kolejnym pomiarze CGM.



Rysunek 3.3: Symulacja regulatora MPC dla scenariusza A.

Na wykresie widoczny jest niewielki początkowy wzrost poziomu glukozy, wynikający z braku insuliny. Regulator MPC, widząc jej brak w parametrach X_{est} i I_{est} , bardzo szybko reaguje, wyznaczając początkowo większą dawkę. W efekcie poziom glukozy zostaje sprowadzony w okolice wartości docelowej, bez wyraźnego zejścia do dolnej granicy zakresu terapeutycznego.

W dalszej części symulacji glikemia utrzymuje się bardzo blisko celu, a odczyty CGM oscylują wokół wartości docelowej. W porównaniu z regulatorem PID przebieg glukozy jest bardziej stabilny i nie występuje wyraźne przeregulowanie po początkowej reakcji.

Widoczne są jednak dość gwałtowne zmiany podaży insuliny. Wynika to z przyjętej konstrukcji funkcji kosztu oraz sposobu optymalizacji - regulator wybiera dawkę minimalizującą błąd glikemii i koszt insuliny, ale nie zastosowano dodatkowej kary za gwałtowne zmiany dawki między kolejnymi krokami. W praktycznych systemach MPC często dodaje się składnik ograniczający zmienność sterowania.

W scenariuszu A regulator MPC spełnił swoje zadanie bardzo dobrze: szybko ustabilizował glikemię w pobliżu wartości docelowej i utrzymał ją w zakresie terapeutycznym przez większość czasu symulacji. Wynik pokazuje przewagę sterowania predycyjnego nad klasycznym podejściem reaktywnym - MPC wykorzystuje model pacjenta do oceny przyszłych skutków podanej insuliny, dzięki czemu może ograniczyć przeregulowanie i lepiej utrzymać glikemię w pobliżu celu.

Jednocześnie wynik wskazuje na istotne ograniczenie zastosowanej wersji regulatora: sygnał sterujący jest mniej płynny niż oczekiwano. W dalszych eksperymentach można byłoby rozważyć rozszerzenie funkcji kosztu o karę za gwałtowne zmiany podaży insuliny, co mogłoby poprawić stabilność i realizm działania regulatora.

3.3.3 Regulator RL

W odróżnieniu od regulatora PID, który działa na podstawie jawnie zdefiniowanego błędu regulacji, oraz MPC, który w każdym kroku rozwiązuje problem optymalizacji, regulator RL podejmuje decyzję na podstawie wcześniej wyuczonej polityki. Oznacza to, że dawka insuliny nie jest obliczana bezpośrednio ze wzoru sterowania, lecz wyznaczana przez sieć neuronową na podstawie aktualnego stanu środowiska.

W pracy zastosowano uproszczone podejście, inspirowane algorytmem *DDPG*. Regulator składa się z dwóch sieci neuronowych: aktora oraz krytyka. Aktor odpowiada za wyznaczanie dawki insuliny, natomiast krytyk ocenia jakość decyzji podjętej przez aktora.

Sieć aktora przyjmuje wektor stanu i zwraca wartość dawki insuliny:

```
1 class Actor(nn.Module):
```

```

2         def __init__(self, state_dim, action_dim):
3             super(Actor, self).__init__()
4
5             self.layer = nn.Sequential(
6                 nn.Linear(state_dim, 128),
7                 nn.ReLU(),
8                 nn.Linear(128, 64),
9                 nn.ReLU(),
10                nn.Linear(64, action_dim),
11                nn.Sigmoid()
12            )
13
14        def forward(self, x):
15            return self.layer(x) * MAX_U

```

Listing 3.13: Architektura sieci aktora w regulatorze RL

Zastosowanie funkcji *Sigmoid* ogranicza wyjście sieci do zakresu od 0 do 1, a przemnożenie przez MAX_U ogranicza maksymalną dawkę insuliny. W badaniu przyjęto:

```

1     MAX_U = 0.06
2     MAX_DELTA_U = 0.003

```

Listing 3.14: Parametry regulatora RL

Oznacza to, że maksymalna dawka insuliny wynosiła 0,06 j./min, czyli 3,6 j./h. Dodatkowo zastosowano ograniczenie maksymalnej zmiany dawki między kolejnymi decyzjami. Miało to na celu zmniejszenie impulsowego dawkowania insuliny i uzyskanie bardziej równomiernej infuzji.

Sieć krytyka przyjmuje stan oraz akcję i zwraca ocenę jakości danej decyzji:

```

1     class Critic(nn.Module):
2         def __init__(self, state_dim, action_dim):
3             super(Critic, self).__init__()
4
5             self.layer = nn.Sequential(
6                 nn.Linear(state_dim + action_dim, 128),
7                 nn.ReLU(),
8                 nn.Linear(128, 64),
9                 nn.ReLU(),
10                nn.Linear(64, 1)
11            )
12

```

```

13     def forward(self, state, action):
14         return self.layer(torch.cat([state, action], dim=1)
            )

```

Listing 3.15: Architektura sieci krytyka w regulatorze RL

Wektor stanu przekazywany do aktora składał się z czterech elementów oznaczających: odczyt CGM, trend zmian glukozy, przewidywane opóźnienie działania insuliny, poprzednio podaną dawkę.

```

1     state = np.array([
2         current_cgm / 200.0,
3         trend / 5.0,
4         x_est * 100.0,
5         u_ddpg / MAX_U
6     ], dtype=np.float32)

```

Listing 3.16: Wektor stanu dla regulatora RL

Trening przeprowadzono wieloscenariuszowo. Oznacza to, że agent nie był uczony wyłącznie w warunkach scenariusza A, lecz także w obecności posiłku, wysiłku fizycznego oraz zakłóceń sensora CGM:

```

1     kind = np.random.choice(
2         ["rest", "meal", "exercise", "sensor"],
3         p=[0.30, 0.30, 0.25, 0.15],
4     )

```

Listing 3.17: Losowy wybór scenariusza treningowego dla regulatora RL

Takie podejście miało na celu nauczenie agenta bardziej uniwersalnej strategii sterowania, odpornej na różne warunki pracy systemu zamkniętej pętli.

Funkcja nagrody została zaprojektowana tak, aby promować utrzymywanie glukozy w pobliżu wartości docelowej, a jednocześnie silnie karać sytuacje niebezpieczne:

```

1     def ddp_reward(g, u_prev, u_new):
2
3         r = -((g - G_TARGET) ** 2) / 100.0
4
5         if g < 70.0:
6             r -= 120.0
7
8         if g < 55.0:
9             r -= 300.0
10

```

```
11     if g > 180.0:
12         r -= (g - 180.0) * 0.3
13
14     r -= 500.0 * (u_new - u_prev) ** 2
15     r -= 50.0 * (u_new ** 2)
16
17     return float(r)
```

Listing 3.18: Funkcja nagrody dla regulatora RL

Największą karę przypisano hipoglikemii, ponieważ stanowi ona bezpośrednie zagrożenie dla pacjenta. Dodatkowo wprowadzono karę za gwałtowne zmiany dawki oraz za nadmierną ilość podanej insuliny. Dzięki temu agent był zachęcany nie tylko do utrzymywania glukozy w zakresie docelowym, ale również do bardziej płynnego dawkowania.

Trening przeprowadzono przez 1200 epizodów. Na początku treningu do akcji aktora dodawano większy szum eksploracyjny, co pozwalało agentowi sprawdzać różne strategie dawkowania. W kolejnych epizodach poziom szumu stopniowo zmniejszano, aby agent coraz częściej wykorzystywał już wyuczoną politykę.

```
1     n_episodes = 1200
2
3     for episode in range(n_episodes):
4         explore_noise = max(0.001, 0.008 * (1.0 - episode /
5             n_episodes))
6
7         transitions = run_training_episode(explore_noise=
8             explore_noise)
9
10        for transition in transitions:
11            memory.append(transition)
12            train_step()
```

Listing 3.19: Parametry dla treningu regulatora RL

Po zakończeniu treningu działanie regulatora sprawdzono w scenariuszu A.

```
1     def simulate_rl_scenario_a(params, actor_model, cgm_lag_min
2         =15):
3         steps = 720
4         lag_steps = int(cgm_lag_min)
5
6         G = np.zeros(steps)
```


```

6      U = np.zeros(steps)
7      CGM = np.zeros(steps)
8
9      g = 100.0
10     x = 0.0
11     i = 0.0
12     G[0] = g
13     x_est = 0.0
14     i_est = 0.0
15     history_cgm_seen = [100.0] * 30
16
17     u_ddpg = 0.013
18     current_cgm = 100.0
19
20     CGM[0] = 100.0
21
22     for k in range(steps - 1):
23         if k % 5 == 0:
24             idx_lag = max(0, k - lag_steps)
25             current_cgm = G[idx_lag] + np.random.normal
26                 (0.0, 1.2)
27             history_cgm_seen.append(current_cgm)
28             CGM[k] = current_cgm
29             trend = (current_cgm - history_cgm_seen[-4]) /
30                 15.0
31             state = np.array([
32                 current_cgm / 200.0,
33                 trend / 5.0,
34                 x_est * 100.0,
35                 u_ddpg / MAX_U
36             ], dtype=np.float32)
37
38             with torch.no_grad():
39                 u_raw = actor_model(
40                     torch.FloatTensor(state).unsqueeze(0)
41                 ).numpy()[0, 0]
42
43             u_ddpg = limit_insulin_change(u_raw, u_ddpg)
44         else:
45             CGM[k] = CGM[max(0, k - 1)]

```

```
44     U[k] = u_ddpg
45
46     dG = -params["p1"] * (g - params["G_b"]) - x * g
47     dX = -params["p2"] * x + params["p3"] * (i - params
48           ["I_b"])
49     dI = -params["n"] * i + (1.0 / params["Vi"]) *
50           u_ddpg
51     g += dG
52     x += dX
53     i += dI
54
55     if g < 20.0:
56         g = 20.0
57     G[k + 1] = g
58
59     dX_est = -params["p2"] * x_est + params["p3"] *
60           i_est
61     dI_est = -params["n"] * i_est + (1.0 / params["Vi"]
62           ) * u_ddpg
63     x_est += dX_est
64     i_est += dI_est
65
66     CGM[-1] = CGM[-2]
67
68     return pd.DataFrame({
69         "time": np.arange(steps),
70         "G": G,
71         "U": U,
72         "CGM": CGM
73     })
```

Listing 3.20: Symulacja regulatora RL dla scenariusza A



Rysunek 3.4: Symulacja regulatora RL dla scenariusza A.

W scenariuszu A regulator RL reaguje na wzrost poziomu glukozy poprzez stopniowe zwiększenie podaży insuliny. Reakcja nie jest natychmiastowa, ponieważ decyzje regulatora podejmowane są na podstawie opóźnionych odczytów CGM. Widoczne punkty pomiarowe CGM podążają za rzeczywistą glikemią z przesunięciem czasowym, co odzwierciedla opóźnienie sensora względem rzeczywistego poziomu glukozy we krwi.

Po początkowym wzroście glikemii stopniowo obniża się i stabilizuje w pobliżu wartości docelowej. Od około drugiej godziny symulacji poziom glukozy utrzymuje się na względnie stałym poziomie, nieco powyżej celu 100 mg/dL. Przez cały czas symulacji glikemia pozostaje w zakresie terapeutycznym 70-180 mg/dL, a regulator nie doprowadza do epizodu hipoglikemii.

Sygnal podaży insuliny po fazie początkowej przyjmuje stabilny charakter. Regulator utrzymuje niewielką, regularną dawkę insuliny z drobnymi korektami, co wskazuje na płynną pracę algorytmu. Brak dużych, pojedynczych impulsów insuliny wynika z zastosowanego ograniczenia maksymalnej zmiany dawki oraz uwzględnienia poprzedniej dawki w wektorze stanu regulatora.

W porównaniu z regulatorem PID, RL wykazuje bardziej stabilny przebieg glikemii po fazie początkowej. PID szybciej i silniej reagował na bieżący błąd regulacji, co pozwalało skutecznie sprowadzać glikemię do zakresu docelowego, ale jednocześnie prowadziło do większych oscylacji oraz bardziej skokowego dawkowania insuliny. Regulator RL działa ostrożniej - nie dąży agresywnie do natychmiastowego osiągnięcia celu, lecz stabilizuje glikemię nieco powyżej wartości zadanej, ograniczając ryzyko hipoglikemii.

W porównaniu z regulatorem MPC, RL nie rozwiązuje w każdym kroku problemu

optymalizacji i nie korzysta jawnie z modelu predykcyjnego do wyznaczania przyszłego przebiegu glukozy. Decyzja o dawce insuliny wynika z polityki wyuczonej podczas treningu. Na wykresie widoczny jest bardziej równomierny sygnał podaży insuliny niż w przypadku MPC, gdzie pomimo zastosowania kary za zmianę dawki nadal występowały miejscami skokowe korekty. Z drugiej strony MPC w scenariuszu A szybciej stabilizował glikemię blisko celu, podczas gdy RL utrzymuje poziom glukozy lekko powyżej wartości docelowej.

W scenariuszu A regulator RL spełnił swoje podstawowe zadanie: doprowadził glikemię do stabilnego poziomu i utrzymywał ją w zakresie docelowym przez cały czas trwania symulacji. Największe odchylenie wystąpiło w początkowej fazie, kiedy regulator kompensował brak aktywnej insuliny. Po ustabilizowaniu układu przebieg glukozy był równomierny, a oscylacje niezauważalne.

3.4 Scenariusz B

Celem tego scenariusza było wprowadzenie jednego z najważniejszych czynników zmieniających glikemię u pacjentów, jakim jest posiłek zawierający dużą ilość węglowodanów, powodujący nagły wzrost glikemii. W przypadku niepodania insuliny, może to spowodować podniesienie glikemii o nawet 200mg/dL.

W scenariuszu B założono:

- posiłek zawierający 50 gram węglowodanów
- brak wysiłku fizycznego,
- standardowy odczyt CGM.


3.4.1 Regulator PID

W implementacji posiłek został odwzorowany za pomocą profilu R_a , opisującego tempo pojawiania się glukozy w organizmie po spożyciu węglowodanów.

```
1 Ra = meal_ra_profile(meal_carbs, meal_time_min, times)
```

Listing 3.21: Profil R_a dla posiłku w regulatorze PID

Do przeprowadzenia eksperymentu wykorzystano funkcję *simulate_scenario_b*, która rozszerza wcześniejszą symulację regulatora PID o wpływ posiłku



Rysunek 3.5: Symulacja regulatora PID dla scenariusza B.

W pierwszej części symulacji, przed wystąpieniem posiłku, zachowanie regulatora jest podobne do scenariusza A. Glikemia początkowo wzrasta, po czym regulator zwiększa podaż insuliny i sprowadza poziom glukozy w okolice wartości docelowej.

W czwartej godzinie symulacji wprowadzony zostaje posiłek zawierający 50 g węglowodanów. Powoduje on gwałtowny wzrost glikemii, której maksymalna wartość osiąga około 250 mg/dL. Odczyty CGM podążają za rzeczywistą glikemią z opóźnieniem, dlatego regulator PID reaguje dopiero wtedy, gdy wzrost poziomu glukozy jest widoczny w sygnale pomiarowym.

Po wykryciu hiperglikemii regulator zwiększa podaż insuliny. Widoczna jest wyraźna dawka korekcyjna, której zadaniem jest ograniczenie wzrostu glukozy oraz sprowadzenie jej z powrotem do zakresu docelowego. Ze względu na opóźnienie działania insuliny oraz opóźnienie pomiaru CGM, reakcja regulatora nie jest natychmiastowa. Po głównym wzroście poposiłkowym widoczny jest także kolejny, mniejszy wzrost glikemii, który wynika z dalszego działania profilu wchłaniania glukozy oraz dynamiki układu.


W dalszej części symulacji poziom glukozy stopniowo obniża się i powraca do zakresu docelowego. Pod koniec symulacji glikemia znajduje się blisko dolnej granicy zakresu terapeutycznego, ale nie dochodzi do ciężkiej hipoglikemii. Sygnał podaży insuliny pozostaje podwyższony przez dłuższy czas po posiłku, co wynika z działania członu całkującego oraz utrzymującego się błędu regulacji po okresie hiperglikemii.

W scenariuszu B regulator PID poradził sobie z obniżeniem glikemii po posiłku, jednak jego reakcja była opóźniona i doprowadziła do dużego wzrostu poposiłkowego. Wynik ten pokazuje ograniczenia klasycznego regulatora PID w sytuacjach dynamicz-

nych. Regulator nie przewiduje przyszłego wzrostu glukozy wynikającego z posiłku, lecz reaguje dopiero na błąd widoczny w odczytach CGM. W praktyce może to prowadzić do wysokiej hiperglikemii po posiłku, długotrwałej zwiększonej podaży insuliny i możliwej hipoglikemii kilka godzin po posiłku.

3.4.2 Regulator MPC

Przy regulatorze MPC, również wykorzystano funkcję symulującą scenariusz A, jednak rozszerzoną o profil posiłku R_a .



Rysunek 3.6: Symulacja regulatora MPC dla scenariusza B.

Po wystąpieniu posiłku w czwartej godzinie symulacji glikemia zaczyna gwałtownie rosnąć. Maksymalna wartość glukozy osiąga około 260–270 mg/dL, co oznacza znaczną hiperglikemię. Odczyty CGM podążają za rzeczywistą glikemią z opóźnieniem, dlatego regulator MPC nie reaguje natychmiast na rzeczywisty początek wzrostu poziomu glukozy.

Po wykryciu wzrostu glikemii regulator zwiększa podaż insuliny. Wzrost dawki jest jednak niewystarczająco szybki, aby zapobiec dużemu przekroczeniu zakresu docelowego. Wynika to z faktu, że regulator nie otrzymuje informacji o nadchodzącym posiłku ani o aktualnym profilu R_a , lecz działa na podstawie opóźnionych odczytów CGM i modelu wewnętrznego nieuwzględniającego bezpośrednio wchłaniania węglowodanów.

W dalszej części symulacji poziom glukozy stopniowo obniża się i powraca w kierunku wartości docelowej. Proces ten trwa jednak kilka godzin, co pokazuje, że mimo zastosowania sterowania predykcyjnego regulator ma ograniczoną skuteczność w sytuacji niezgłoszonego posiłku. Glikemia wraca do zakresu docelowego dopiero po dłuż-


szym czasie, a w końcowej części symulacji stabilizuje się blisko 100 mg/dL.

Sygnał podaży insuliny ma charakter zmienny i miejscami impulsowy. Wynika to z przyjętej funkcji kosztu, która karze odchylenie glukozy od celu oraz wielkość dawki insuliny, ale nie zawiera osobnego składnika ograniczającego gwałtowne zmiany sterowania. W praktycznej implementacji regulatora MPC można byłoby dodać karę za zmianę dawki, aby uzyskać bardziej płynną pracę pompy insulinowej.

W scenariuszu B regulator MPC ostatecznie sprowadził glikemię z powrotem do zakresu docelowego, jednak nie zapobiegł wysokiej hiperglikemii poposiłkowej. Wynik ten pokazuje, że nawet regulator predykcyjny może działać reaktywnie, jeśli jego model wewnętrzny nie uwzględnia informacji o posiłku. W porównaniu ze scenariuszem A zadanie było znacznie trudniejsze, ponieważ wzrost glukozy był szybki, a pomiar CGM opóźniony względem rzeczywistej glikemii.

3.4.3 Regulator RL

Ponownie jak przy poprzednich regulatorach, implementacja scenariusza RL została rozszerzona o dodatkowy składnik R_a



Rysunek 3.7: Symulacja regulatora RL dla scenariusza B.

W czwartej godzinie symulacji pojawia się posiłek zawierający 50 g węglowodanów. Po jego wystąpieniu glikemia zaczyna gwałtownie rosnąć i osiąga wartość maksymalną około 215-220 mg/dL. Odczyty CGM podążają za rzeczywistym poziomem glukozy z opóźnieniem, dlatego regulator nie reaguje natychmiast na początek wzrostu. Dopiero gdy efekt posiłku widoczny jest w sygnale CGM, agent zwiększa podaż insuliny.

W odpowiedzi na wzrost glikemii regulator RL stopniowo zwiększa dawkę insuliny.

Sygnał podaży nie ma charakteru pojedynczego gwałtownego impulsu, lecz przyjmuje postać płynniejszego wzrostu, po którym następuje stopniowe obniżanie dawki. Wynika to z ograniczenia maksymalnej zmiany dawki oraz z uwzględnienia poprzedniej dawki w stanie wejściowym regulatora.

Po osiągnięciu maksimum glikemia zaczyna stopniowo spadać. Proces powrotu do wartości zbliżonych do celu trwa jednak kilka godzin. W drugiej połowie symulacji poziom glukozy pozostaje podwyższony, lecz stopniowo zbliża się do docelowej glikemii. Regulator nie doprowadza do hipoglikemii, co wskazuje na ostrożny charakter wyuczonej polityki.

W scenariuszu B regulator RL poradził sobie z zakłóceniem częściowo skutecznie. Ograniczył wzrost glikemii i po czasie sprowadził ją w kierunku wartości docelowej, jednak nie zapobiegł przejściowej hiperglikemii poposiłkowej. Wynika to przede wszystkim z faktu, że agent nie otrzymywał informacji o posiłku z wyprzedzeniem i działał reaktywnie, na podstawie opóźnionych odczytów CGM.

W porównaniu z regulatorem PID, RL generuje bardziej płynny sygnał podaży insuliny i nie wykazuje tak silnych skoków sterowania. W porównaniu z MPC nie rozwiązuje problemu optymalizacji w każdym kroku, lecz korzysta z wyuczonej polityki. W analizowanym scenariuszu jego zachowanie można uznać za bezpieczne, ponieważ nie doprowadził do hipoglikemii, jednak czas powrotu glikemii po posiłku był dłuższy w stosunku do PID.

3.5 Scenariusz C

W scenariuszu C sprawdzono działanie regulatorów w sytuacji odpowiadającej wysiłkowi fizycznemu. Wysiłek fizyczny jest jednym z trudniejszych zakłóceń w kontroli glikemii, ponieważ może zwiększać zużycie glukozy przez organizm oraz podnosić wrażliwość tkanek na insulinę. W praktyce oznacza to większe ryzyko spadku poziomu glukozy, szczególnie wtedy, gdy w organizmie znajduje się już aktywna insulina.

W implementacji scenariusz wysiłku został odwzorowany poprzez czasową zmianę parametrów modelu Bergmana. W czwartej godzinie symulacji, na okres dwóch godzin, zwiększono wartość parametru p_3 , odpowiadającego za wrażliwość organizmu na insulinę, oraz parametru p_1 , opisującego tempo zmian glukozy niezależne od działania insuliny:

```
1  if exercise_start <= t_min <= (exercise_start +
2      exercise_duration):
3      current_p1 = params["p1"] * 1.5
4      current_p3 = params["p3"] * 3.0
      exercise_flag[k] = 1.0
```

```


5     else:
6         current_p1 = params["p1"]
7         current_p3 = params["p3"]

```

Listing 3.22: Zmiana parametrów modelu Bergmana w scenariuszu C

3.5.1 Regulator PID

Dla regulatora PID w implementacji scenariusza C przy każdej iteracji pętli sprawdzane jest, czy aktualny czas symulacji znajduje się w przedziale wysiłku fizycznego. Jeżeli tak, parametry modelu zostają tymczasowo zmienione. Następnie generowany jest opóźniony i zaszumiony odczyt CGM, na podstawie którego regulator PID wyznacza dawkę insuliny. Ostatnim krokiem jest aktualizacja modelu Bergmana z wykorzystaniem aktualnych, zależnych od czasu parametrów *current_p1* i *current_p3*.



Rysunek 3.8: Symulacja regulatora PID dla scenariusza C.

W czwartej godzinie symulacji rozpoczyna się okres wysiłku fizycznego. W tym czasie model pacjenta staje się bardziej wrażliwy na insulinę, a glukoza jest szybciej obniżana. Na wykresie widoczny jest spadek glikemii w czasie trwania wysiłku, w 5 godzinie wykraczający poza dolną granicę zakresu terapeutycznego. Regulator PID reaguje na ten spadek poprzez ograniczenie podaży insuliny, jednak reakcja ta jest opóźniona, ponieważ algorytm korzysta z odczytów CGM opóźnionych względem rzeczywistego poziomu glukozy.

Po zakończeniu okresu wysiłku parametry modelu wracają do wartości podstawowych. Glikemia ponownie wzrasta i stabilizuje się w zakresie docelowym, choć widoczne


są oscylacje wokół wartości zadanej. Sygnał podaży insuliny pozostaje zmienny i miejscami skokowy, co wynika z reaktywnego charakteru regulatora PID oraz obecności szumu w odczytach CGM.

W scenariuszu C regulator PID był w stanie utrzymać glikemię głównie w zakresie terapeutycznym, jednak pojawiły się wyraźne wahania poziomu glukozy. Największym problemem okazała się reakcja na zmianę wrażliwości insulinowej podczas wysiłku. Regulator PID nie posiada informacji o rozpoczęciu aktywności fizycznej ani o zmianie parametrów organizmu, dlatego może reagować dopiero wtedy, gdy spadek glukozy pojawi się w opóźnionym sygnale CGM.

Wynik pokazuje ograniczenia regulatora PID w warunkach zmiennej fizjologii pacjenta. W scenariuszach takich jak wysiłek fizyczny regulator powinien możliwie szybko ograniczać podaż insuliny, aby zmniejszyć ryzyko hipoglikemii. Klasyczny PID działa jednak głównie reaktywnie, przez co jego skuteczność zależy od szybkości i dokładności pomiaru CGM oraz od odpowiedniego doboru parametrów regulatora.

3.5.2 Regulator MPC

W regulatorze MPC wykorzystano tą samą instrukcję warunkową zmieniającą wartość parametrów p_1 i p_3 na czas wysiłku fizycznego.



Rysunek 3.9: Symulacja regulatora MPC dla scenariusza C.

W czasie trwania wysiłku glikemia obniża się w okolice dolnej granicy zakresu terapeutycznego, a miejscami spada nieznacznie poniżej niej. Nie występuje jednak gwałtowna, ciężka hipoglikemia. Regulator ogranicza podaż insuliny w odpowiedzi na


spadek glukozy, ale ze względu na opóźnienie CGM oraz niezgodność modelu predykcyjnego z rzeczywistą fizjologią nie jest w stanie całkowicie zapobiec przeregulowaniu.

Po zakończeniu wysiłku parametry pacjenta wracają do wartości podstawowych. Glikemia stopniowo wzrasta i stabilizuje się w pobliżu wartości docelowej. Nie występują tu widoczne oscylacje, co może być przewagą MPC nad regulatorem PID w tym scenariuszu. W końcowej części symulacji poziom glukozy utrzymuje się w zakresie terapeutycznym, a regulator kontynuuje dawkowanie insuliny z umiarkowanymi korektami.

Sygnał podaży insuliny pozostaje zmienny, jednak zastosowanie kary za zmianę dawki oraz ograniczenia maksymalnej zmiany sterowania zmniejsza jego impulsowy charakter. Mimo to widoczne są skokowe korekty, wynikające z dyskretnego działania regulatora, szumu pomiarowego oraz konieczności reagowania na nieoczekiwaną zmianę fizjologii pacjenta.

3.5.3 Regulator RL

W regulatorze RL wykorzystano tą samą instrukcję warunkową zmieniającą wartość parametrów p_1 i p_3 na czas wysiłku fizycznego.



Rysunek 3.10: Symulacja regulatora RL dla scenariusza C.

W czwartej godzinie symulacji rozpoczyna się wysiłek fizyczny. W tym czasie rzeczywisty model pacjenta staje się bardziej wrażliwy na insulinę, a glukoza zaczyna szybciej spadać. Na wykresie widoczne jest obniżenie glikemii poniżej wartości docelowej, z minimum w okolicach dolnej granicy zakresu terapeutycznego. Spadek ten wynika z nagłej zmiany fizjologii pacjenta, której agent nie zna bezpośrednio.

Regulator RL reaguje na spadek glikemii poprzez ograniczenie podaży insuliny. Widoczne punkty CGM podążają za przebiegiem G_{true} z opóźnieniem, dlatego regulator rozpoznaje spadek dopiero po pewnym czasie.

Po zakończeniu wysiłku parametry modelu wracają do wartości podstawowych. Glikemia stopniowo wzrasta i stabilizuje się w pobliżu wartości docelowej. W końcowej części symulacji poziom glukozy utrzymuje się blisko 100 mg/dL, a sygnał podaży insuliny ma względnie równomierny charakter z niewielkimi korektami.

W scenariuszu C regulator RL poradził sobie poprawnie, choć widoczny jest przejściowy spadek glikemii w czasie wysiłku fizycznego. Agent nie doprowadził jednak do gwałtownej hipoglikemii i po zakończeniu zakłócenia stopniowo przywrócił glikemię do wartości bliskich celowi. Wynik pokazuje, że regulator RL potrafi reagować na zmianę warunków fizjologicznych, ale jego skuteczność jest ograniczona przez brak bezpośredniej informacji o wysiłku oraz opóźnienie pomiaru CGM.

W porównaniu z regulatorem PID, RL generuje bardziej płynny sygnał podaży insuliny i wykazuje brak oscylacji po zakończeniu zakłócenia. W tym scenariuszu jego największą zaletą jest stabilny profil dawkowania, natomiast ograniczeniem pozostaje reaktywny charakter odpowiedzi na niespodziewany wysiłek fizyczny.

3.6 Scenariusz D


W ostatnim scenariuszu sprawdzono działanie regulatorów w warunkach zakłóconego pomiaru CGM. Celem było określenie, jak poszczególne algorytmy radzą sobie w sytuacji, gdy sygnał pomiarowy nie odzwierciedla rzeczywistego poziomu glukozy. Jest to szczególnie ważne w systemach zamkniętej pętli, ponieważ błędnie podjęte decyzje mogą prowadzić do niebezpiecznych dla pacjenta sytuacji.

W scenariuszu tym nie wprowadzono posiłku czy wysiłku fizycznego, a jedynym zakłóceniem był błąd pomiaru CGM. Do sygnału sensora dodano trzy rodzaje zakłóceń:

- zwiększony szum losowy, symulujący gorszą jakość pomiaru,
- dryft 1 mg/dL/h, symulujący stopniowe odchodzenie od rzeczywistej glikemii,
- pojedyncze błędy pomiarowe, ± 40 mg/dL co godzinę.

3.6.1 Regulator PID

Zgodnie z założeniami scenariusza D, do odczytów CGM dodano zwiększony szum losowy, dryft oraz pojedyncze błędy pomiarowe.



Rysunek 3.11: Symulacja regulatora PID dla scenariusza D.


W symulacji rzeczywista glikemia utrzymuje się głównie w zakresie terapeutycznym, najczęściej w okolicach 80-100 mg/dL, jednak w porównaniu do scenariusza A dla tego regulatora, rzadziej utrzymuje się w wartości docelowej 100 mg/dL. Widoczne są liczne wahania wynikające z reakcji regulatora na zaburzone odczyty. Punkty pomiarowe CGM są bardziej rozproszone, co wynika z dodanego szumu, dryftu oraz błędów pomiarowych. Regulator PID reaguje na te zakłócenia, co prowadzi do większej zmienności podaży insuliny, a co za tym idzie, do większych wahań glikemii.

Szczególnie widoczne są reakcje regulatora na pojedyncze błędy. Jeżeli sensor chwilowo zawyża odczyt, regulator interpretuje to jako hiperglikemię i zwiększa dawkę. Jeżeli natomiast odczyt zostaje zaniżony, dawka może zostać ograniczona.

Regulator PID utrzymał glikemię w zakresie docelowym, jednak odbyło się to kosztem dużej zmienności podaży insuliny. Liczne impulsy podaży insuliny wskazują, że regulator był wrażliwy na zakłócenia pomiaru. Z punktu widzenia bezpieczeństwa taki sposób działania może być niekorzystny, ponieważ może to prowadzić do nieuzasadnionej zmiany dawki leku.

Podsumowując, regulator PID poradził sobie z utrzymaniem glikemii w zakresie terapeutycznym, ale wykazał ograniczoną odporność na zakłócenia CGM. Wysoka zmienność sygnału insuliny pokazuje, że klasyczny PID wymaga dodatkowych mechanizmów filtracji sygnału lub ograniczeń szybkości zmian dawki, aby mógł bezpiecznie działać w warunkach zaszumionego pomiaru.

3.6.2 Regulator MPC



Rysunek 3.12: Symulacja regulatora MPC dla scenariusza D.


W symulacji rzeczywisty poziom glukozy pozostaje stosunkowo stabilny i przez większość czasu utrzymuje się w pobliżu wartości docelowej 100 mg/dL. Widoczne są jednak rozproszone punkty CGM, które miejscami znacznie odbiegają od rzeczywistej glikemii.

Regulator MPC reaguje na zakłócony sygnał CGM, jednak jego odpowiedź jest mniej gwałtowna niż w przypadku klasycznego regulatora PID. Wynika to z zastosowania horyzontu predykcji, kary za zmianę dawki oraz ograniczenia maksymalnej zmiany sterowania. Mimo występowania błędnych odczytów, rzeczywista glikemia nie wykazuje dużych oscylacji i pozostaje w zakresie terapeutycznym.

Sygnał podaży insuliny nadal ma charakter skokowy, co jest związane z dyskretnym działaniem regulatora oraz okresową optymalizacją dawki. Widoczne są krótkie wzrosty podaży insuliny, szczególnie w momentach, w których zakłócony odczyt CGM sugeruje wyższy poziom glukozy. W porównaniu z PID, impulsy są jednak mniej ekstremalne, a przebieg glikemii jest bardziej stabilny.

Podsumowując, regulator MPC wykazał większą odporność na zakłócenia CGM niż regulator PID. Dzięki wykorzystaniu modelu predykcyjnego, kary za zmianę dawki oraz ograniczenia maksymalnej zmiany sterowania utrzymał glikemię w stabilnym zakresie. Ograniczeniem pozostaje jednak fakt, że w przypadku silnych błędów pomiarowych regulator nadal może podejmować decyzje na podstawie nieprawidłowego obrazu stanu pacjenta.

3.6.3 Regulator RL



Rysunek 3.13: Symulacja regulatora RL dla scenariusza D.

W symulacji rzeczywista glikemia utrzymuje się w zakresie terapeutycznym, głównie w okolicach 100-110 mg/dL. Widoczne punkty CGM są bardziej rozproszone niż w scenariuszach bez zakłóceń. Część odczytów wyraźnie odbiega od rzeczywistego przebiegu glukozy, co wynika z dodanych zakłóceń.

Pomimo zakłóconych danych wejściowych sygnał podaży insuliny pozostaje względnie stabilny. Regulator generuje niewielkie korekty dawki, jednak nie pojawiają się bardzo wysokie, pojedyncze impulsy insuliny. Oznacza to, że agent nie reaguje nadmiernie agresywnie na pojedyncze błędne pomiary. Jest to efekt zarówno wyuczonej polityki, jak i zastosowanego ograniczenia maksymalnej zmiany dawki.

W porównaniu z regulatorem PID, regulator RL wykazuje mniejszą wrażliwość na zakłócenia pomiarowe. PID bezpośrednio reagował na błąd między odczytem CGM a wartością docelową, co prowadziło do licznych skokowych zmian podaży insuliny. W przypadku RL sygnał sterujący jest bardziej równomierny, a pojedyncze błędne odczyty CGM nie powodują tak gwałtownych korekt.

W porównaniu z regulatorem MPC, RL nie wykorzystuje jawnego modelu predykcyjnego ani nie rozwiązuje problemu optymalizacji w każdym kroku. Decyzje podejmowane są na podstawie wyuczonej polityki. Mimo tego regulator utrzymuje glikemię stabilnie w zakresie docelowym. MPC również dobrze radził sobie z utrzymaniem rzeczywistej glikemii, jednak jego sygnał sterujący miał bardziej skokowy charakter wynikający z okresowej optymalizacji dawki.

Podsumowując, w scenariuszu D regulator RL poradził sobie dobrze. Utrzymał

rzeczywistą glikemię w zakresie terapeutycznym mimo opóźnionego i zaburzonego sygnału CGM. Najważniejszą zaletą regulatora była stabilność sygnału sterującego oraz brak nadmiernie agresywnych reakcji na pojedyncze błędy pomiarowe. Ograniczeniem pozostaje jednak fakt, że agent nadal zależy od jakości danych CGM i w przypadku silniejszych lub długotrwałych błędów sensora mógłby podejmować nieprawidłowe decyzje.

Rozdział 4

Wyniki i wnioski

4.1 Kryteria oceny

Ocena skuteczności działania regulatorów w systemach zamkniętej pętli została określona poprzez zestaw porównywalnych miar, które odzwierciedlają zarówno bezpieczeństwo pacjenta, jak i jakość kontroli glikemii. Użyte zostały wskaźniki powszechnie stosowane w diabetologii oparte na danych z systemów CGM, uzupełnione o miary charakterystyczne dla systemów sterowania.

Wszystkie kryteria obliczano na podstawie przebiegu rzeczywistej glikemii uzyskanej w symulacjach oraz sygnału sterującego odpowiadającego podaży insuliny. Odczyty CGM były wykorzystywane jako dane wejściowe regulatorów, natomiast do oceny jakości działania przyjęto rzeczywisty poziom glukozy G_{true} , ponieważ reprezentuje on faktyczny stan pacjenta w modelu symulacyjnym.

4.1.1 Czas w zakresie

Podstawowym kryterium oceny był wskaźnik TIR (ang. *Time in range*), określający procent czasu, w którym poziom glukozy znajdował się w zakresie docelowym. W pracy przyjęto zakres terapeutyczny:

$$70 \text{ mg/dL} \leq G(t) \leq 180 \text{ mg/dL} \quad (4.1)$$

Wskaźnik ten jest jednym z najważniejszych parametrów klinicznych, gdyż silnie koreluje z długoterminowymi powikłaniami cukrzycy. Wyższa wartość TIR oznacza lepszą jakość regulacji glikemii. Dodatkowo zmierzono również czas, w jakim glikemia miała wartości powyżej (TAR) jak i poniżej (TBR) wartości docelowej.

4.1.2 Średni poziom glukozy

Średni poziom glukozy obliczano jako średnią arytmetyczną wartości glikemii w całym czasie trwania symulacji:

$$\overline{G} = \frac{1}{N} \sum_{k=1}^N G(k) \quad (4.2)$$

gdzie

$\overline{G}$ – średnia wartość glikemii,

N – liczba próbek pomiarowych,

$G(k)$ – wartość glukozy w k -tej próbce.

Miara ta pozwala określić, czy dany regulator ma tendencję do utrzymywania glikemii powyżej, poniżej czy w pobliżu wartości docelowej. Wartość średniej glikemii jest istotna również dlatego, że w praktyce klinicznej długookresowa średnia glikemia jest powiązana z wartością hemoglobiny glikowanej HbA1c. HbA1c odzwierciedla średni poziom glukozy z dłuższego okresu, najczęściej około 2–3 miesięcy, i jest jednym z podstawowych wskaźników oceny kontroli cukrzycy.

W niniejszej pracy średnia glikemia została obliczona na podstawie krótkich, 12-godzinnych symulacji, dlatego nie należy interpretować jej jako rzeczywistego odpowiednika klinicznego HbA1c. Może ona jednak służyć jako przybliżona miara tendencji regulatora do utrzymywania glukozy na określonym poziomie. Niższa średnia glikemia, zbliżona do wartości docelowej, wskazuje na lepszą dokładność regulacji, o ile nie jest osiągnięta kosztem zwiększonego ryzyka hipoglikemii.

Dodatkowo, poza średnim poziomem glukozy, obliczono średni błąd bezwzględny względem wartości docelowej, oznaczany jako *MAE* (ang. *Mean Absolute Error*). Wskaźnik ten określa, o ile średnio wartości glikemii odbiegały od przyjętego celu regulacji.

W pracy jako wartość docelową glikemii przyjęto:

$$G_{\text{target}} = 100 \text{ mg/dL} \quad (4.3)$$

Średni błąd bezwzględny *MAE* obliczono według wzoru:

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |G_i - G_{\text{target}}| \quad (4.4)$$

gdzie:

G_i – wartość glikemii w i -tej próbce,

G_{target} – wartość docelowa glikemii,

N – liczba próbek w analizowanym przebiegu.

Niższa wartość MAE oznacza, że regulator dokładniej utrzymywał poziom glukozy w pobliżu wartości docelowej. W przeciwieństwie do samej średniej glikemii, MAE uwzględnia wielkość odchylenia od celu niezależnie od ich kierunku. Oznacza to, że zarówno zbyt wysokie, jak i zbyt niskie wartości glukozy zwiększają wartość tego wskaźnika.

4.1.3 Epizody hipoglikemii i hiperglikemii

Bezpieczeństwo pacjenta oceniano poprzez analizę epizodów hipoglikemii i hiperglikemii. Za hipoglikemię przyjęto wartości:

$$G(t) < 70 \text{ mg/dL} \quad (4.5)$$

natomiast za hiperglikemię:

$$G(t) > 180 \text{ mg/dL} \quad (4.6)$$

Epizod zdefiniowano jako ciągły fragment symulacji, w którym glikemia pozostawała poza zakresem docelowym. Oznacza to, że kilka kolejnych próbek poniżej 70 mg/dL traktowano jako jeden epizod hipoglikemii, a nie jako wiele oddzielnych zdarzeń.

Regulator można uznać za bezpieczniejszy, jeśli minimalizuje zarówno liczbę, jak i czas trwania stanów niepożądanych. Szczególnie istotne są epizody hipoglikemii, ponieważ mogą stanowić bezpośrednie zagrożenie dla pacjenta.

4.1.4 Zużycie insuliny

Zużycie insuliny stanowi miarę intensywności działania regulatora. Obliczono je jako sumę podaży insuliny w całym czasie symulacji:

$$U_{\text{total}} = \sum_{k=1}^N U(k) \cdot \Delta t \quad (4.7)$$

gdzie:

U_{total} – całkowita podaż insuliny,

$U(k)$ – podaż insuliny w k -tym kroku symulacji,

Δt – krok czasowy symulacji,

N – liczba kroków symulacji.

Niższe zużycie insuliny przy jednoczesnym zachowaniu wysokiego TIR może wskazywać na bardziej efektywną i łagodną strategię sterowania. Nie oznacza to jednak automatycznie lepszego działania regulatora. Zbyt mała podaż insuliny może prowadzić do hiperglikemii, dlatego kryterium to należy interpretować razem z TIR , liczbą epizodów hiper- i hipoglikemii oraz średnim poziomem glukozy.

4.1.5 Stabilność i oscylacje glikemii

Ostatnim kryterium była stabilność przebiegu glikemii. Analizowano ją na podstawie amplitudy wahań, występowania oscylacji po zakłóceniach oraz maksymalnego przeregulowania. Dodatkowo obliczono współczynnik zmienności:

$$CV = \frac{\sigma_G}{\bar{G}} \cdot 100\% \quad (4.8)$$

gdzie:

CV – współczynnik zmienności glikemii,

σ_G – odchylenie standardowe poziomu glukozy,

$\bar{G}$ – średnia wartość glikemii.

Niższa wartość CV oznacza bardziej stabilny przebieg glikemii. Regulatory powodujące silne oscylacje uznano za mniej korzystne, nawet jeśli osiągały wysoki TIR . W praktyce duże wahania glukozy mogą zwiększać ryzyko późniejszych epizodów hipo- lub hiperglikemii.

4.2 Wyniki

Wyniki porównania regulatorów PID, MPC i RL zestawiono na podstawie czterech scenariuszy badawczych: stabilnej glikemii, posiłku, wysiłku fizycznego oraz zakłóceń pomiaru CGM. Dla każdego regulatora obliczono wartości średnie lub sumaryczne dla wszystkich scenariuszy.

Tabela 4.1: Porównanie działania regulatorów PID, MPC oraz RL

Reg.	TIR [%]	TBR [%]	TAR [%]	Średnia glikemia	MAE [mg/dL]	Ep. hipo.	Ep. hiper.	Insulina [U]	CV [%]
PID	97,22	1,39	1,39	101,42	15,83	2	1	54,94	22,48
MPC	91,46	0,59	7,95	112,40	17,75	1	1	44,47	15,86
RL	96,56	1,22	2,22	112,77	15,78	1	1	40,25	15,01

Najwyższy wskaźnik *TIR* uzyskał regulator PID, dla którego glikemia znajdowała się w zakresie docelowym przez 97,22% czasu. Bardzo zbliżony wynik osiągnął regulator RL, uzyskując *TIR* równy 96,56%. Najniższy *TIR* odnotowano dla MPC, który osiągnął 91,46%. Wszystkie regulatory utrzymywały jednak glikemię w zakresie docelowym przez większość czasu symulacji.

Pod względem czasu poniżej zakresu docelowego najkorzystniej wypadł regulator MPC, dla którego TBR wyniósł 0,59%. RL uzyskał wartość 1,22%, natomiast PID 1,39%. Różnice te wskazują, że MPC najrzadziej doprowadzał do wartości poniżej 70 mg/dL, jednak jego większym problemem była hiperglikemia. Wartość TAR dla MPC wyniosła 7,95%, podczas gdy dla PID tylko 1,39%, a dla RL 2,22%.

Najniższy średni poziom glukozy uzyskał regulator PID, dla którego średnia glikemia wyniosła 101,42 mg/dL. Była to wartość najbliższa przyjętemu celowi 100 mg/dL. Dla MPC i RL średnia glikemia była wyższa i wyniosła odpowiednio 112,40 mg/dL oraz 112,77 mg/dL. Pod względem średniego bezwzględnego odchylenia od celu najlepszy wynik uzyskały RL i PID osiągając *MAE* równe odpowiednio 15,78 mg/dL i 15,83 mg/dL, a MPC 17,75 mg/dL.

Pod względem zużycia insuliny najbardziej oszczędny okazał się regulator RL, który podał łącznie 40,25 jednostki insuliny. MPC zużył 44,47 jednostki, natomiast PID 54,94 jednostki. Oznacza to, że PID osiągnął najlepsze wyniki w zakresie *TIR* i *MAE*, ale wymagał największej ilości insuliny. RL uzyskał bardzo wysoki *TIR* przy najniższym zużyciu insuliny, co wskazuje na bardziej łagodną strategię sterowania.

Pod względem stabilności, mierzonej współczynnikiem zmienności *CV*, najlepszy wynik uzyskał regulator RL — 15,01%. Bardzo zbliżony wynik osiągnął MPC — 15,86%. Największą zmienność glikemii zaobserwowano dla PID, którego *CV* wyniosło 22,48%. Oznacza to, że mimo najwyższego *TIR* regulator PID powodował większe wahania glikemii niż pozostałe metody.

4.3 Wnioski

Celem pracy było porównanie działania trzech metod sterowania w systemie zamkniętej pętli do regulacji glikemii: klasycznego regulatora PID, regulatora predykcyjnego MPC oraz regulatora opartego na uczeniu ze wzmocnieniem. Regulatory zostały przetestowane w czterech scenariuszach obejmujących warunki stabilne, posiłek, wysiłek fizyczny oraz zakłócenia pomiaru CGM.

Ocena skuteczności została przeprowadzona na podstawie kilku kryteriów: czasu przebywania glikemii w zakresie docelowym, średniego poziomu glukozy, średniego odchylenia od wartości docelowej, liczby epizodów hipoglikemii i hiperglikemii, całkowitego zużycia insuliny oraz stabilności przebiegu glikemii. Wszystkie te kryteria są istotne, jednak w kontekście systemów automatycznego dawkowania insuliny szczególne znaczenie mają bezpieczeństwo pacjenta oraz stabilność działania regulatora. Oznacza to, że najwyższy TIR nie powinien być jedynym kryterium wyboru najlepszego algorytmu, jeżeli jednocześnie regulator powoduje silne oscylacje, częste epizody hipoglikemii lub gwałtowne zmiany podaży insuliny.

Najwyższy wskaźnik TIR uzyskał regulator PID. Oznacza to, że w analizowanych scenariuszach najdłużej utrzymywał glikemię w zakresie docelowym 70-180 mg/dL. PID osiągnął również najniższą średnią glikemię oraz najniższe średnie bezwzględne odchylenie od wartości docelowej. Wyniki te pokazują, że klasyczny regulator PID skutecznie sprowadzał poziom glukozy w pobliże celu regulacji. Jednocześnie jego działanie było najbardziej oscylacyjne. Regulator ten charakteryzował się największym współczynnikiem zmienności glikemii oraz największym zużyciem insuliny. W scenariuszu zakłóconego pomiaru CGM widoczne były liczne skokowe zmiany dawki, co wskazuje na wysoką wrażliwość PID na błędy pomiarowe. Z tego względu, mimo bardzo dobrego wyniku TIR, regulator PID można uznać za mniej korzystny pod względem stabilności i odporności na zakłócenia.

Regulator MPC uzyskał najniższy udział czasu poniżej zakresu docelowego, co jest korzystne z punktu widzenia ograniczania ryzyka hipoglikemii. Jednocześnie osiągnął najniższy *TIR* oraz najwyższy udział czasu powyżej zakresu docelowego. Oznacza to, że w porównaniu z pozostałymi regulatorami częściej dopuszczał przejściową hiperglikemię. Wynikało to między innymi z predykcyjnego charakteru regulatora oraz zależności jego działania od modelu wewnętrznego. Gdy rzeczywiste zachowanie pacjenta odbiegało od założeń modelu, na przykład podczas posiłku lub zmiany wrażliwości insulinowej, MPC nie zawsze był w stanie wystarczająco szybko i dokładnie przewidzieć dalszy przebieg glikemii. Zaletą MPC była natomiast stosunkowo dobra stabilność glikemii

Regulator RL uzyskał najbardziej zrównoważony wynik z punktu widzenia bezpie-

czeństwa i stabilności. Jego *TIR* był bardzo zbliżony do wyniku regulatora PID, ale jednocześnie zużycie insuliny było najniższe spośród wszystkich badanych metod. RL osiągnął także najniższy współczynnik zmienności glikemii, co oznacza najbardziej stabilny przebieg poziomu glukozy. Sygnał podaży insuliny był bardziej równomierny niż w przypadku PID i mniej podatny na pojedyncze błędne odczyty CGM. Wynikało to zarówno z wyuczonej polityki działania, jak i z zastosowania ograniczenia maksymalnej zmiany dawki oraz uwzględnienia poprzedniej podaży insuliny w stanie wejściowym agenta.

Największą zaletą regulatora RL była stabilność działania. Regulator ten nie dążył agresywnie do natychmiastowego osiągnięcia wartości docelowej, lecz utrzymywał glikemię w bezpiecznym zakresie przy niewielkich oscylacjach. W scenariuszach z zakłóceniami, szczególnie przy zaszumionym sygnale CGM, RL nie generował gwałtownych impulsów insuliny w odpowiedzi na pojedyncze błędne pomiary. Takie zachowanie można uznać za korzystne z punktu widzenia bezpieczeństwa pacjenta, ponieważ nadmiernie agresywne dawkowanie insuliny mogłoby prowadzić do hipoglikemii.

Na podstawie uzyskanych wyników nie można jednoznacznie wskazać jednego regulatora jako najlepszego we wszystkich aspektach. PID najlepiej utrzymywał glikemię blisko wartości docelowej i osiągnął najwyższy *TIR*. MPC charakteryzował się najmniejszym czasem poniżej zakresu docelowego, co wskazuje na ograniczenie ryzyka hipoglikemii, ale częściej dopuszczał hiperglikemię. RL zapewnił natomiast najbardziej stabilne i oszczędne sterowanie, uzyskując bardzo wysoki *TIR* przy najniższym zużyciu insuliny i najniższym współczynniku zmienności.

Jeżeli priorytetem jest wyłącznie utrzymanie glikemii jak najbliżej wartości docelowej, najkorzystniej wypada regulator PID. Jeżeli jednak najważniejsze są bezpieczeństwo pacjenta, stabilność przebiegu glikemii, ograniczenie oscylacji oraz łagodny sygnał sterujący, najbardziej obiecującym rozwiązaniem wydaje się regulator RL. Jego działanie było mniej agresywne, ale bardziej stabilne, co w praktycznym systemie wspomagającym terapię może być szczególnie istotne.

Wnioski z przeprowadzonych symulacji wskazują, że skuteczność regulatora w systemie zamkniętej pętli powinna być oceniana przez wiele kryteriów. Wysoki *TIR* jest bardzo ważnym wskaźnikiem, ale nie powinien być analizowany w oderwaniu od liczby epizodów hipoglikemii, zmienności glikemii, zużycia insuliny oraz odporności na błędy pomiarowe. Regulator przeznaczony do zastosowań związanych z terapią cukrzycy powinien działać nie tylko skutecznie, ale przede wszystkim bezpiecznie, stabilnie i przewidywalnie.

Dalsze prace mogłyby obejmować zastosowanie bardziej zaawansowanego modelu pacjenta, większej liczby scenariuszy testowych oraz indywidualizację parametrów metabolicznych. W przypadku regulatora RL istotne byłoby również zastosowanie bar-

dziej stabilnych algorytmów uczenia, oraz przeprowadzenie szerszej walidacji bezpieczeństwa.

Podsumowując, przeprowadzone badania pokazały, że wszystkie trzy regulatory mogą wspierać regulację glikemii w uproszczonym systemie zamkniętej pętli, ale różnią się charakterem działania. PID uzyskał najlepszą dokładność regulacji, MPC ograniczał czas poniżej zakresu docelowego, natomiast RL zapewnił najbardziej stabilne i oszczędne sterowanie. W kontekście bezpieczeństwa pacjenta i stabilności pracy układu regulator RL można uznać za najbardziej zrównoważone rozwiązanie spośród badanych metod.

Spis listingów

3.1	Parametry symulacji	28
3.2	Parametry modelu Bergmana	28
3.3	Implementacja modelu Bergmana	29
3.4	Model pojawiania się glukozy po posiłku	31
3.5	Model systemu CGM	31
3.6	Parametry modelu CGM	32
3.7	Implementacja regulatora PID	35
3.8	Symulacja regulatora PID dla scenariusza A	35
3.9	Parametry regulatora PID	37
3.10	Funkcja przewidywania stanu w regulatorze MPC	38
3.11	Funkcja kosztu w regulatorze MPC	39
3.12	Symulacja regulatora MPC dla scenariusza A	39
3.13	Architektura sieci aktora w regulatorze RL	42
3.14	Parametry regulatora RL	43
3.15	Architektura sieci krytyka w regulatorze RL	43
3.16	Wektor stanu dla regulatora RL	44
3.17	Losowy wybór scenariusza treningowego dla regulatora RL	44
3.18	Funkcja nagrody dla regulatora RL	44
3.19	Parametry dla treningu regulatora RL	45
3.20	Symulacja regulatora RL dla scenariusza A	45
3.21	Profil Ra dla posiłku w regulatorze PID	49
3.22	Zmiana parametrów modelu Bergmana w scenariuszu C	53

Spis tabel

4.1	Porównanie działania regulatorów PID, MPC oraz RL	67
-----	---	----

Spis rysunków

3.1	Symulacja modelu Bergmana bez regulatora.	33
3.2	Symulacja regulatora PID dla scenariusza A.	37
3.3	Symulacja regulatora MPC dla scenariusza A.	41
3.4	Symulacja regulatora RL dla scenariusza A.	48
3.5	Symulacja regulatora PID dla scenariusza B.	50
3.6	Symulacja regulatora MPC dla scenariusza B.	51
3.7	Symulacja regulatora RL dla scenariusza B.	52
3.8	Symulacja regulatora PID dla scenariusza C.	54
3.9	Symulacja regulatora MPC dla scenariusza C.	55
3.10	Symulacja regulatora RL dla scenariusza C.	56
3.11	Symulacja regulatora PID dla scenariusza D.	58
3.12	Symulacja regulatora MPC dla scenariusza D.	59
3.13	Symulacja regulatora RL dla scenariusza D.	60

Bibliografia

- [1] Richard N. Bergman i in. „Quantitative Estimation of Insulin Sensitivity”. W: *American Journal of Physiology-Endocrinology and Metabolism* 236.6 (1979), E667–E677. DOI: 10.1152/ajpendo.1979.236.6.E667.
- [2] Richard N. Bergman, Lawrence S. Phillips i Claudio Cobelli. „Physiologic Evaluation of Factors Controlling Glucose Tolerance in Man: Measurement of Insulin Sensitivity and Beta-Cell Glucose Sensitivity from the Response to Intravenous Glucose”. W: *Journal of Clinical Investigation* 68.6 (1981), s. 1456–1467. DOI: 10.1172/JCI110398.
- [3] Lalo Magni i in. „Model Predictive Control of Type 1 Diabetes: An in Silico Trial”. W: *Journal of Diabetes Science and Technology* 1.6 (2007), s. 804–812. DOI: 10.1177/193229680700100603. URL: <https://pubmed.ncbi.nlm.nih.gov/19885152/>.
- [4] Boris Kovatchev i William Clarke. „Peculiarities of the Continuous Glucose Monitoring Data Stream and Their Impact on Developing Closed-Loop Control Technology”. W: *Journal of Diabetes Science and Technology* 2.1 (2008), s. 158–163. DOI: 10.1177/193229680800200125.
- [5] Eda Cengiz i William V. Tamborlane. „A Tale of Two Compartments: Interstitial Versus Blood Glucose Monitoring”. W: *Diabetes Technology & Therapeutics* 11.S1 (2009), S11–S16. DOI: 10.1089/dia.2009.0002.
- [6] D. Barry Keenan i in. „Delays in Minimally Invasive Continuous Glucose Monitoring Devices: A Review of Current Technology”. W: *Journal of Diabetes Science and Technology* 3.5 (2009), s. 1207–1214. DOI: 10.1177/193229680900300528.
- [7] Mirosław Tomera. „Regulator PID”. W: *Automatyka, Elektryka, Zakłócenia* 1.2 (2010), s. 89–93. URL: <https://www.epismo-aez.pl/artykul.php?id=127> (dostęp 12.06.2026).
- [8] C. Wei i in. „Measurement delay associated with the Guardian RT continuous glucose monitoring system”. W: *Diabetic Medicine* 27.1 (2010), s. 117–122. DOI: 10.1111/j.1464-5491.2009.02887.x.

- [9] Roman Hovorka. „Closed-loop insulin delivery: from bench to clinical practice”. W: *Nature Reviews Endocrinology* 7.7 (2011), s. 385–395. DOI: 10.1038/nrendo.2011.32. URL: <https://pubmed.ncbi.nlm.nih.gov/21343892/>.
- [10] Simone Del Favero i in. „First Use of Model Predictive Control in Outpatient Wearable Artificial Pancreas”. W: *Diabetes Care* 37.5 (2014), s. 1212–1215. DOI: 10.2337/dc13-1631. URL: <https://diabetesjournals.org/care/article/37/5/1212/38190/First-Use-of-Model-Predictive-Control-in>.
- [11] Erin Digitale. *New research shows how to keep diabetics safer during sleep*. Stanford Medicine News Center. 8 maja 2014. URL: <https://med.stanford.edu/news/insights/2014/05/new-research-keeps-diabetics-safer-during-sleep.html> (dostęp 11.06.2026).
- [12] Masoud Goharimanesh, Ali Lashkaripour i Ali Abouei Mehrizi. „Fractional Order PID Controller for Diabetes Patients”. W: *Journal of Computational Applied Mechanics* 46.1 (2015), s. 69–76. DOI: 10.22059/JCAMECH.2015.53395. URL: https://jcamech.ut.ac.ir/issue_7209_7210.html.
- [13] Günther Schmelzeisen-Redeker i in. „Time Delay of CGM Sensors: Relevance, Causes, and Countermeasures”. W: *Journal of Diabetes Science and Technology* 9.5 (2015), s. 1006–1015. DOI: 10.1177/1932296815590154.
- [14] Andrea Facchinetti. „Continuous Glucose Monitoring Sensors: Past, Present and Future Algorithmic Challenges”. W: *Sensors* 16.12 (2016), s. 2093. DOI: 10.3390/s16122093.
- [15] Kyriaki Saiti i in. „A Review of Model Prediction in Diabetes and of Designing Glucose Regulators Based on Model Predictive Control for the Artificial Pancreas”. W: *Information Technology in Bio- and Medical Informatics*. T. 10443. Lecture Notes in Computer Science. Cham: Springer, 2017, s. 66–81. DOI: 10.1007/978-3-319-64265-9_6.
- [16] Konstantinos Papatheodorou i in. „Complications of Diabetes 2017”. W: *Journal of Diabetes Research* 2018 (2018), s. 3086167. DOI: 10.1155/2018/3086167. URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC5866895/>.
- [17] Kathryn W. Weaver i Irl B. Hirsch. „The Hybrid Closed-Loop System: Evolution and Practical Applications”. W: *Diabetes Technology & Therapeutics* 20.S2 (2018), S216–S223. DOI: 10.1089/dia.2018.0091. URL: <https://journals.sagepub.com/doi/full/10.1089/dia.2018.0091>.

- [18] Dessi P. Zaharieva i in. „Lag Time Remains with Newer Real-Time Continuous Glucose Monitoring Technology During Aerobic Exercise in Adults Living with Type 1 Diabetes”. W: *Diabetes Technology & Therapeutics* 21.6 (2019), s. 313–321. DOI: 10.1089/dia.2018.0364.
- [19] Sakshi Bhonsle i Sahaj Saxena. „A review on control-relevant glucose–insulin dynamics models and regulation strategies”. W: *Proceedings of the Institution of Mechanical Engineers, Part I: Journal of Systems and Control Engineering* 234.5 (2020), s. 596–608. DOI: 10.1177/0959651819870328. URL: <https://journals.sagepub.com/doi/10.1177/0959651819870328>.
- [20] Klemen Dovc i Tadej Battelino. „Evolution of Diabetes Technology”. W: *Endocrinology and Metabolism Clinics of North America* 49.1 (2020), s. 1–18. DOI: 10.1016/j.ecl.2019.10.009. URL: <https://www.sciencedirect.com/science/article/pii/S088985291930091X>.
- [21] Miguel Tejedor, Ashenafi Zebene Woldaregay i Fred Godtliebsen. „Reinforcement learning application in diabetes blood glucose control: A systematic review”. W: *Artificial Intelligence in Medicine* 104 (2020), s. 101836. ISSN: 0933-3657. DOI: <https://doi.org/10.1016/j.artmed.2020.101836>. URL: <https://www.sciencedirect.com/science/article/pii/S0933365718304548>.
- [22] Brinnae Bent, Maria Henriquez i Jessilyn Dunn. „cgmquantify: Python and R Packages for Comprehensive Analysis of Interstitial Glucose and Glycemic Variability from Continuous Glucose Monitor Data”. W: *IEEE Open Journal of Engineering in Medicine and Biology* 2 (2021), s. 179–186. DOI: 10.1109/OJEMB.2021.3105816.
- [23] Richard N. Bergman. „Origins and History of the Minimal Model of Glucose Regulation”. W: *Frontiers in Endocrinology* 11 (2021), s. 583016. DOI: 10.3389/fendo.2020.583016.
- [24] Taiyu Zhu i in. „Basal Glucose Control in Type 1 Diabetes Using Deep Reinforcement Learning: An In Silico Validation”. W: *IEEE Journal of Biomedical and Health Informatics* 25.4 (2021), s. 1223–1232. DOI: 10.1109/JBHI.2020.3014556. URL: <https://pubmed.ncbi.nlm.nih.gov/32755873/>.
- [25] Rasoul Zahedifar i Ali Keymasi Khalaji. „Control of Blood Glucose Induced by Meals for Type-1 Diabetics Using an Adaptive Backstepping Algorithm”. W: *Scientific Reports* 12 (2022), s. 12228. DOI: 10.1038/s41598-022-16535-2.

- [26] T. Quattrin, L. D. Mastrandrea i L. S. K. Walker. „Type 1 diabetes”. W: *The Lancet* 401.10394 (2023), s. 2149–2162. DOI: 10.1016/S0140-6736(23)00223-4. URL: [https://www.thelancet.com/journals/lancet/article/PIIS0140-6736\(23\)00223-4/fulltext](https://www.thelancet.com/journals/lancet/article/PIIS0140-6736(23)00223-4/fulltext).
- [27] Omer Saleem i Jamshed Iqbal. „Complex-order PID controller design for enhanced blood-glucose regulation in Type-I diabetes patients”. W: *Measurement and Control* 56.9–10 (2023), s. 1811–1825. DOI: 10.1177/00202940231189504. URL: <https://journals.sagepub.com/doi/10.1177/00202940231189504>.
- [28] Xuehui Yu i in. „ARLPE: A meta reinforcement learning framework for glucose regulation in type 1 diabetics”. W: *Expert Systems with Applications* 228 (2023), s. 120156. ISSN: 0957-4174. DOI: <https://doi.org/10.1016/j.eswa.2023.120156>. URL: <https://www.sciencedirect.com/science/article/pii/S0957417423006589>.
- [29] Yan Feng Zhao i in. „A safe-enhanced fully closed-loop artificial pancreas controller based on deep reinforcement learning”. W: *PLOS ONE* 20.1 (2025), e0317662. DOI: 10.1371/journal.pone.0317662. URL: <https://pubmed.ncbi.nlm.nih.gov/39869550/>.